

Projekt Szeregi Czasowe

Diana Morzhak, Mateusz Walo, Dominika Zydorczyk

Cel i zarys projektu

Celem niniejszego projektu jest przeanalizowanie danych dotyczących miesięcznej ceny takich metali szlachetnych jak złoto, miedź oraz srebro wyrażonej w dolarach amerykańskich w okresie lat 2005 - 2025 za 1 uncję takiego metalu. Okres ten obejmuje 20 lat które gospodarczo i ekonomicznie miały bardzo wiele wydarzeń które miały wpływ na wachanie się ceny tego jakże cennego surowca. W ciągu tych 20 lat mieliśmy doczynienia z pandemią COVID-19, wybuchem wojny na Ukrainie oraz ekspansją rozwoju sztucznej inteligencji, bardzo ciekawe czasu :)

Dlaczego akurat metale szlachetne? Jest to surowiec który wykorzystywano jeszcze zanim powstała waluta dolara amerykańskiego, i ten surowiec jest niezwykle ważny dla globalnej gospodarki.

Dane dotyczące złota zostały pobrane przez API Pythonowe z witryny <https://freegoldapi.com/data/latest.csv> i odpowiednio sformatowane tak aby plik z danymi nadawał się do dalszej analizy, skrypty pythonowe użyte do pobrania i obróbki danych znajdują się w repozytorium w folderze `utils/`

Opis jak pobrane zostały dane miedzi

Opis jak zostały pobrane dane o srebrze // analogicznie do tego co napisałem o złocie

Przedstawienie danych wszystkich metali

zrobi tą część osoba która będzie robiła swoją część jako ostatnia i tutaj wykresiki wszystkich trzech metali jednocześnie, z zaznaczeniem ważnych dat - covid, wojna etc. to taki dalszy wstęp jeszcze przed tym czy wgl zajmiemy się na poważnie szeregami :)

Analiza szeregu czasowego dla miesięcznej ceny uncji złota

Pytania badawcze


1. Czy szereg wykazuje trend lub sezonowość?
2. Czy po transformacji (log, różnice) szereg jest stacjonarny?
3. Który model (ETS/ARIMA/baseline) daje najlepszą prognozę na 12–24 miesiące?
4. Czy w danych występują zmiany strukturalne (np. okolice 2008, 2020)?

Złoto: miesięczna cena (USD/oz), 2005–2025



Szereg miesięcznych cen złota w USD w latach 2005–2025 wykazuje wyraźny długookresowy trend wzrostowy, ale nie jest to wzrost jednolity w czasie. W danych widać co najmniej kilka faz (reżimów): silny wzrost do okolic 2011–2012, następnie kilkuletnie osłabienie i stabilizacja, ponowny wzrost w latach 2019–2021 oraz bardzo dynamiczne przyspieszenie w końcowej części próby (2024–2025), gdzie ceny osiągają nowe maksima. Zmienność także wydaje się rosnąć wraz z poziomem cen, co sugeruje niestacjonarność szeregu na poziomach i potencjalną potrzebę transformacji (np. logarytmowania) oraz analizy różnic/log-zwrotów. Już na etapie EDA można też podejrzewać występowanie zmian strukturalnych, dlatego w dalszej części projektu oprócz klasycznych modeli (ETS/ARIMA) zostanie sprawdzona stabilność w czasie oraz jakość prognoz na wydzielonym zbiorze testowym.


Rozkład cen złota (miesięcznie)



Rozkład miesięcznych cen złota jest wyraźnie prawostronnie asymetryczny: większość obserwacji koncentruje się w niższych przedziałach cenowych, a długi ogon po prawej stronie wynika z relatywnie krótkiego, ale bardzo wysokiego poziomu cen

w końcowej części próby. Taki kształt rozkładu jest typowy dla danych ekonomicznych mierzonych w poziomach i sugeruje, że wariancja może zależeć od poziomu (efekt skali).

Heatmapa cen: miesiąc vs rok




Heatmapa cen w układzie miesiąc-rok pozwala jednocześnie ocenić dwa aspekty szeregów czasowych **sezonowość** (wzorce powtarzające się w kolumnach miesięcy) oraz **zmiany poziomu** w czasie (różnice między wierszami lat). W przedstawionych danych nie widać stabilnego, powtarzalnego wzorca miesięcznego - kolory w obrębie pojedynczego roku są zwykle do siebie zbliżone, a ewentualne różnice między miesiącami są małe w porównaniu do zmian między latami. To sugeruje, że klasyczna sezonowość kalendarzowa (miesięczna) jest słaba lub drugorzędna. Jednocześnie wyraźnie widać **zmianę reżimów cenowych**: lata 2005–2007 są relatywnie „jasne”, okres ok. 2010–2012 jest zauważalnie „ciemniejszy”, następnie następuje kilkuletnia stabilizacja na umiarkowanym poziomie, a od okolic 2020 widać przejście do wyraźnie wyższych poziomów, z najsilniejszym przyciemnieniem w latach 2024–2025. Z punktu widzenia modelowania oznacza to, że w danych dominują zmiany poziomu w czasie, a komponent sezonowy – jeśli w ogóle występuje – nie jest kluczowy, co uzasadnia skupienie się na transformacjach/stacjonarności oraz modelach dobrze radzących sobie ze zmianami poziomu.

Trend: aproksymacja wielomianowa + wybór stopnia

Wybór stopnia wielomianu


Dobór stopnia wielomianu trendu (AIC)



Zgodnie z podejściem wykładowym, stopień wielomianu trendu dobrano na podstawie kryterium informacyjnego Akaikiego **AIC**, które równoważy jakość dopasowania z karą za złożoność modelu. Wraz ze wzrostem stopnia wielomianu AIC systematycznie maleje, co oznacza, że prostsze trendy (stopnie 1–3) nie oddają w pełni nieliniowego charakteru zmian cen w czasie. Minimum AIC uzyskano dla stopnia **11** (zaznaczone na wykresie), dlatego ten wariant przyjęto jako najlepszy kompromis między dopasowaniem a liczbą parametrów w ramach rozważanej rodziny modeli. Jednocześnie spłaszczenie krzywej AIC dla wysokich stopni sugeruje, że poprawa dopasowania po przekroczeniu okolic 7–8 jest już relatywnie niewielka, co w praktyce może oznaczać ryzyko „dopasowania się” do lokalnych wahań. Z tego powodu trend wielomianowy traktujemy przede wszystkim jako narzędzie opisu deterministycznej składowej.

Dopasowanie trendu do reszty


Trend wielomianowy (stopień 11)



Dopasowana krzywa dobrze oddaje **nieliniowy przebieg długookresowych zmian** (wzrost do ok. 2011–2012, spadek/stabilizacja w kolejnych latach oraz silne przyspieszenie po 2020), traktując krótkookresowe wahania jako składnik

Wyglądanie: MA i EWMA

Wyglądanie: MA(12) i EWMA



Na wykresie zastosowano dwie klasyczne metody wygładzania: **MA(12)** oraz **EWMA**.

MA(12) (*Moving Average*, 12-miesięczna średnia ruchoma) polega na zastąpieniu obserwacji średnią z ostatnich (lub – jak tu – z okna obejmującego) **12 miesięcy**, co silnie redukuje wahania krótkookresowe i wydobywa **trend/cykl w skali rocznej**. Skutkiem ubocznym jest **opóźnienie (lag)** względem szeregu – MA reaguje wolniej na nagłe zmiany, bo każda nowa obserwacja wpływa na wynik tylko w $1/12$.

EWMA (*Exponentially Weighted Moving Average*, wykładniczo ważona średnia ruchoma) nadaje obserwacjom w przeszłości **malejące wykładniczo wagi**. Formalna definicja ma postać

$$y_t = \lambda x_t + (1 - \lambda) \cdot y_{t-1}$$


Parametr $\lambda = 0.2$ oznacza, że bieżąca obserwacja ma 20% wagi, a pozostałe 80% “dziedziczone” jest z poprzedniego wygładzenia. W praktyce EWMA jest **bardziej responsywna** niż MA i szybciej “podąża” za zmianami trendu, jednocześnie tłumiąc szum.

Interpretując wynik: obie krzywe wygładzające potwierdzają nieliniowy przebieg długookresowy – wzrost do ok. 2011–2012, późniejsze osłabienie/stabilizację oraz ponowne przyspieszenie po 2019–2020. W końcowej części próby (ok. 2024–2025) widać gwałtowne zwiększenie tempa wzrostu ceny: **EWMA reaguje na to szybciej**, natomiast **MA(12)** pozostaje bardziej “inercyjna” i wygładza tę zmianę mocniej, przez co jej linia jest bardziej opóźniona. Z punktu widzenia projektu, te metody pełnią rolę opisową: pokazują strukturę trendu i skalę wahań krótkookresowych.

Stacjonarność i transformacje

Logarytmowanie i różnicowanie

Transformacje szeregu: log i różnicowanie loga



«««< HEAD ##### Testy ADF ===== Przed budową modeli stochastycznych często stosuje się transformacje, których celem jest **stabilizacja wariancji** i doprowadzenie szeregu do postaci bliższej **stacjonarnej**. W tym celu wykorzystano dwie standardowe operacje:

1. **Transformacja logarytmiczna** $\log(P_t)$ – zmniejsza wpływ skali (duże wartości nie dominują tak silnie jak w poziomach), a w praktyce często stabilizuje rozrzut i ułatwia interpretację zmian w kategoriach względnych.
2. **Różnicowanie logarytmu** $\Delta \log(P_t) = \log(P_t) - \log(P_{t-1})$ usuwa trend deterministyczny/stochastyczny i w przybliżeniu odpowiada **procentowej stopie zwrotu** (log-zwrotowi). To jedna z najczęściej stosowanych transformacji w analizie finansowej i klasycznym modelowaniu ARIMA, gdy poziomy cen wykazują niestacjonarność.

Interpretacja wykresu:

panel z **log(cena)** nadal pokazuje długookresowy wzorzec (wzrost do ok. 2011–2012, spadek/stabilizacja, a następnie silne przyspieszenie w końcówce próby), czyli sama transformacja logarytmiczna **nie usuwa trendu**, tylko zmienia skalę i “uspokaja” względne różnice.

Natomiast panel z **diff(log(cena))** oscyluje wokół zera i nie wykazuje trwałego trendu, co sugeruje, że różnicowanie logarytmu skutecznie eliminuje komponent długookresowy i daje serię bardziej odpowiednią do dalszych testów stacjonarności oraz identyfikacji struktury zależności (ACF/PACF). Jednocześnie widoczne są okresy większej i mniejszej amplitudy wahań, co wskazuje na zmienność zmieniającą się w czasie.

Testy ADF

ADF - Augmented Dickey - Fuller test

Test ADF służy do sprawdzania, czy szereg ma **pierwiastek jednostkowy**, czyli czy jest **niestacjonarny** w sensie klasycznym (np. zachowuje się jak random walk z trendem). „Augmented” oznacza, że do równania dodaje się opóźnienia (lag order), by usunąć autokorelację reszt.

- **Hipoteza zerowa H_0 :** szereg jest **niestacjonarny** (ma pierwiastek jednostkowy).
- **Hipoteza alternatywna H_1 :** szereg jest **stacjonarny**.

KPSS - Kwiatkowski - Phillips - Schmidt - Shin

KPSS jest komplementarny do ADF: sprawdza stacjonarność „od drugiej strony”.

- **Hipoteza zerowa H_0 :** szereg jest **stacjonarny**

- **Hipoteza alternatywna H1:** szereg jest **niestacjonarny**. »»»> d65a931 (wnioski i reformat zlota)

Augmented Dickey-Fuller Test

```
data: na.omit(gold$log_price)
Dickey-Fuller = -1.7675, Lag order = 6, p-value = 0.6737
alternative hypothesis: stationary
```

Wniosek: p-value jest bardzo duże, więc **nie mamy podstaw aby odrzucić H_0** . To oznacza, że **log(cena)** nadal zachowuje się jak szereg **niestacjonarny** (ma trend / składową losową typu random walk). Sama transformacja logarytmiczna stabilizuje skalę, ale **nie usuwa niestacjonarności poziomów**.

Augmented Dickey-Fuller Test

```
data: na.omit(gold$dlog_price)
Dickey-Fuller = -4.7958, Lag order = 6, p-value = 0.01
alternative hypothesis: stationary
```

Wniosek: p-value jest bardzo małe, więc **odrzucaamy H_0** . Oznacza to, że **różnice logarytmów (log-zwroty)** są **stacjonarne** (przynajmniej w sensie ADF). To klasyczny rezultat dla danych finansowych: poziomy są niestacjonarne, a przyrosty/log-zwroty są bliższe stacjonarności.

KPSS Test for Level Stationarity



```
data: na.omit(gold$log_price)
KPSS Level = 3.0892, Truncation lag parameter = 5, p-value = 0.01
```

Wniosek: p-value jest małe, więc **odrzucaamy H_0 o stacjonarności poziomym**. Czyli KPSS potwierdza, że **log(cena)** jest **niestacjonarna**. Wskazuje na spójność z ADF na log_price oba testy wskazują **niestacjonarność**.

KPSS Test for Level Stationarity

```
data: na.omit(gold$dlog_price)
KPSS Level = 0.26519, Truncation lag parameter = 5, p-value = 0.1
```

ACF/PACF

ACF: diff(log(cena))**PACF: diff(log(cena))****Diagnostyka reszt trendu****Losowość**

Runs Test

```
data: na.omit(reszty)
statistic = -10.478, runs = 44, n1 = 126, n2 = 126, n = 252, p-value <
2.2e-16
alternative hypothesis: nonrandomness
```

Test serii (Runs Test) sprawdza, czy znaki reszt pojawiają się w sposób losowy (H_0 : losowość). Otrzymano **p-value < 2.2e-16**, więc zdecydowanie **odrzucaamy hipotezę o losowości**.

Wniosek: reszty po odjęciu trendu wielomianowego wykazują **uporządkowanie/strukturę**, co sugeruje, że sam trend deterministyczny nie opisuje w pełni dynamiki szeregu i w danych pozostają zależności czasowe wymagające modelowania stochastycznego.

Autokorelacja reszt

Box-Ljung test

```
data: na.omit(reszty)
X-squared = 718.76, df = 24, p-value < 2.2e-16
```

Test Boxa-Ljunga weryfikuje hipotezę H_0 , że reszty są **nieautokorelacyjne** (biały szum) do zadanego rzędu opóźnień (tu: 24). Ponieważ **p-value < 2.2e-16**, zdecydowanie **odrzucaamy H_0** . Oznacza to, że w resztach po usunięciu trendu nadal występuje istotna **autokorelacja**, więc trend wielomianowy nie wystarcza – potrzebny jest model uwzględniający zależności czasowe albo dodatkowe składowe strukturalne.

Normalność

Shapiro-Wilk normality test

```
data: sample(na.omit(reszty), min(5000, length(na.omit(reszty))))  
W = 0.9923, p-value = 0.2141
```

Jarque-Bera Normality Test

```
data: na.omit(reszty)  
JB = 2.9561, p-value = 0.2281  
alternative hypothesis: greater
```

Oba testy badają zgodność rozkładu reszt z rozkładem normalnym (H_0 : normalność). Dla Shapiro-Wilka otrzymano **p-value = 0.214**, a dla Jarque-Bera **p-value = 0.228**, więc w obu przypadkach **brak podstaw do odrzucenia normalności** reszt na typowych poziomach istotności. W praktyce oznacza to, że kształt rozkładu reszt nie odbiega istotnie od normalnego; jednocześnie wcześniejsze testy (Runs i Ljung-Box) pokazują, że problemem reszt nie jest rozkład, tylko **zależności czasowe**, które wymagają modelowania.

Heteroskedastyczność


studentized Breusch-Pagan test

```
data: reszty ~ t  
BP = 4.0428, df = 1, p-value = 0.04436
```

Goldfeld-Quandt test

```
data: reszty ~ t  
GQ = 1.318, df1 = 124, df2 = 124, p-value = 0.06277  
alternative hypothesis: variance increases from segment 1 to 2
```

Testy te sprawdzają, czy wariancja reszt jest stała w czasie (H_0 : homoskedastyczność). W teście **Breuscha-Pagana** otrzymano **p-value = 0.044**, co oznacza odrzucenie H_0 na poziomie 0.05 i sugeruje **niejednorodną wariancję** (zmiennność reszt zależną od czasu/trendu). Z kolei **Goldfeld-Quandt** daje **p-value = 0.063**, czyli wynik graniczny: na poziomie 0.05 nie odrzucamy H_0 , ale na 0.1 pojawia się sygnał, że wariancja może rosnąć w późniejszym okresie (zgodnie z hipotezą alternatywną o wzroście wariancji). Łącznie wskazuje to, że w resztach może występować umiarkowana heteroskedastyczność, co uzasadnia transformacje (np. log) i ostrożność w założeniu stałej wariancji przy dalszym modelowaniu.



Modelowanie i prognoza

Podział na train/test

W celu obiektywnej oceny jakości prognoz zastosowano podział na **zbiór uczący (train)** i **zbiór testowy (test)** zgodnie z podejściem z wykładu. Ostatnie **12 miesięcy** ($h = 12$) wydzielono jako test, aby sprawdzić, jak modele radzą sobie z prognozowaniem „w przyszłość” na nieznanych danych. Następnie oba zbiory przekształcono do obiektu typu **ts** sz częstotliwością **12** (dane miesięczne), co umożliwia wykorzystanie metod prognozowania (np. ETS/ARIMA) oraz porównanie prognoz i metryk błędu na jednolitej osi czasu.

Baseline: naive i drift

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	9.305356	49.62299	37.77741	0.6945365	2.931205	0.2141852
Test set	791.992051	923.31462	791.99205	21.5833992	21.583399	4.4903277
ACF1 Theil's U						
Training set	0.2188519	NA				
Test set	0.6956772	4.805866				

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-3.353931e-14	48.74271	37.69181	-0.1236883	2.922483	0.2136999
Test set	7.315072e+02	855.47152	731.50724	19.9172510	19.917251	4.1473992
ACF1 Theil's U						
Training set	0.2188519	NA				
Test set	0.6908275	4.447768				

Poniżej masz krótki, ale treściwy komentarz „wykładowy”: co to za modele benchmarkowe i co mówią Twoje wyniki.

Jako punkt odniesienia zastosowano dwa klasyczne modele.

NAIVE - (model naiwny) zakłada, że prognoza na wszystkie kolejne okresy jest równa **ostatniej obserwacji** ze zbioru uczącego (odpowiednik random walk bez dryfu).

DRIFT - to wariant random walk z **dryfem**, gdzie prognoza oprócz poziomu uwzględnia średnią zmianę w czasie (trend liniowy wynikający z historii). Takie benchmarki są ważne, bo dla szeregów finansowych często trudno je wyraźnie pobić i dopiero porównanie z nimi pokazuje realną wartość bardziej złożonych modeli.

Wyniki na zbiorze testowym (ostatnie 12 miesięcy) wskazują, że oba modele mają duży błąd, ale **DRIFT radzi sobie lepiej niż NAIVE**: RMSE spada z ok. **923** do **855**, a MAE z ok. **792** do **732**. Dodatkowo **ME** (ok. **792** dla NAIVE i **732** dla DRIFT) oznacza **systematyczne zaniżanie prognoz** względem rzeczywistych wartości w teście – testowy fragment szeregu znajduje się wyraźnie wyżej niż poziom „wyniesiony” z treningu. MAPE rzędu **~20–22%** potwierdza, że proste założenia o stałym poziomie (NAIVE) lub stałym tempie wzrostu (DRIFT) nie oddają dobrze dynamiki w ostatnim roku. Te wyniki uzasadniają przejście do modeli adaptacyjnych (ETS/ARIMA) oraz rozważenie transformacji (np. Box–Cox), aby lepiej uchwycić zmianę poziomu i skalę wahań

ETS i ARIMA

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	0.02287788	48.64457	37.53642	-0.1210868	2.910903	0.2128188
Test set	731.50329662	855.46743	731.50330	19.9171398	19.917140	4.1473769
ACF1 Theil's U						
Training set	0.2189265	NA				
Test set	0.6908273	4.447746				

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	0.0117923	47.33331	36.58103	-0.09430785	2.855501	0.2074021
Test set	730.4281178	854.56100	730.42812	19.88520093	19.885201	4.1412810
ACF1 Theil's U						
Training set	-0.005889778	NA				
Test set	0.690831471	4.442572				

W kolejnym kroku zastosowano dwa podstawowe modele prognostyczne **ETS** oraz **ARIMA**.

Model **ETS** (Error–Trend–Seasonal) opisuje szereg poprzez wygładzanie wykładnicze i dobór struktury błędu, trendu i sezonowości (automatycznie wybieranej na podstawie kryteriów informacyjnych).

Z kolei **ARIMA** (AutoRegressive Integrated Moving Average) modeluje zależności autokorelacyjne, a składnik *Integrated* odpowiada za różnicowanie (w praktyce kompensuje niestacjonarność poziomów); dodatkowo dopuszcza komponent sezonowy.

Na zbiorze testowym oba modele osiągają **bardzo podobne wyniki** i są praktycznie równoważne: dla ETS RMSE **855.47**, MAE **731.50**, a dla ARIMA RMSE **854.56**, MAE **730.43**. Oznacza to poprawę względem modelu naiwnego i porównywalny poziom do modelu z dryfem (DRIFT), ale bez wyraźnego przełomu jakości. Dodatkowo wartości **ME 730–731** wskazują, że również ETS i ARIMA **systematycznie zaniżają prognozy** w okresie testowym, co sugeruje, że ostatni rok danych ma wyraźnie wyższy poziom niż wynikałoby to z historii w zbiorze uczącym (zmiana reżimu / silny wzrost). W konsekwencji same modele ETS/ARIMA bez dodatkowych zabiegów (np. transformacji Box–Cox, czyszczenia outlierów lub uwzględnienia zmian strukturalnych) nie eliminują problemu biasu w testowym fragmencie szeregu.”

Modelowanie za pomocą transformacji Boxa-Coxa

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	2.833193	48.78596	37.33237	0.07491358	2.898549	0.211662
Test set	721.334150	844.44634	721.33415	19.63435883	19.634359	4.089721

ACF1 Theil's U

Training set	0.2083711	NA
Test set	0.6900627	4.388795

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-2.098183	47.627	37.23784	-0.1449164	2.895187	0.211126
Test set	630.613989	740.717	630.61399	17.1514423	17.151442	3.575369

ACF1 Theil's U

Training set	0.0692158	NA
Test set	0.6799652	3.845497


Porównanie metryczne modeli

A tibble: 6 x 4

model	RMSE	MAE	MAPE
<chr>	<dbl>	<dbl>	<dbl>
1 ARIMA (BoxCox)	741.	631.	17.2
2 ETS (BoxCox)	844.	721.	19.6
3 ARIMA	855.	730.	19.9
4 ETS	855.	732.	19.9
5 DRIFT	855.	732.	19.9
6 NAIVE	923.	792.	21.6


Porównanie wizualne modeli

Porównanie prognoz cen złota (USD/oz)



Diagnostyka najlepszego modelu

Diagnostyka reszt



Ljung-Box test

```
data: Residuals from ARIMA(0,1,1) with drift
Q* = 20.144, df = 23, p-value = 0.6332
```


```
Model df: 1. Total lags used: 24
```

Zgodnie z podejściem omawianym na wykładzie, po wyborze najlepszego modelu prognozującego należy sprawdzić, czy jego reszty zachowują się jak **biały szum** – tzn. mają średnią bliską zeru, nie wykazują istotnej autokorelacji i nie zawierają systematycznej struktury, której model nie uchwycił. Funkcja `checkresiduals()` łączy w jednej diagnostyce: wykres reszt w czasie, histogram z przybliżeniem rozkładu oraz ACF reszt, a także wykonuje formalny test Ljunga–Boxa.

W teście **Box–Ljung** otrzymano **p-value = 0.6332** (dla 24 opóźnień), więc **brak podstaw do odrzucenia hipotezy zerowej o braku autokorelacji reszt**. Oznacza to, że model ARIMA(0,1,1) z dryfem skutecznie „wyczyścił” zależności liniowe w danych – reszty można traktować jako w przybliżeniu nieskorelowane, co jest kluczowym warunkiem poprawnej specyfikacji modelu.

Wizualnie (ACF i przebieg reszt) nie widać dominujących, systematycznych wzorców, a rozkład reszt jest zbliżony do symetrycznego, co dodatkowo wspiera wniosek, że model jest dobrze dopasowany do struktury średniej. Ewentualne pojedyncze przekroczenia na ACF mogą pojawiać się losowo przy wielu testowanych opóźnieniach i nie muszą oznaczać problemu, jeśli test globalny (Ljung–Box) nie wskazuje autokorelacji.”

Prognoza cen złota – model: ARIMA (BoxCox)



Finalna prognoza została wyznaczona modelem **ARIMA** z transformacją **Box–Cox**, w którym rozrzut rośnie wraz z poziomem cen. Model wskazuje na **kontynuację trendu wzrostowego** w horyzoncie 24 miesięcy, ale jednocześnie przedziały predykcji szybko się rozszerzają, co oznacza rosnącą **niepewność prognozy** wraz z wydłużaniem horyzontu (typowe dla modeli z różnicowaniem/losowym składnikiem trendu). Innymi słowy, ARIMA(BoxCox) sugeruje dalszy wzrost jako scenariusz centralny, lecz dopuszcza szeroki zakres możliwych ścieżek cen w przyszłości.


Zmiany strukturalne i zmienność

Zmiany strukturalne

```
# A tibble: 15 x 2
  changepoint_no date
    <int> <date>
1         1 2005-08-01
2         2 2006-03-01
3         3 2007-06-01
4         4 2007-08-01
5         5 2009-09-01
6         6 2010-09-01
7         7 2011-03-01
8         8 2013-04-01
9         9 2014-08-01
10        10 2016-02-01
11        11 2019-06-01
12        12 2020-03-01
13        13 2023-02-01
14        14 2024-02-01
15        15 2025-01-01
```

Wykrywanie zmian strukturalnych (PELT): srebro

Złota linia: cena • Przerywane linie: wykryte punkty zmiany reżimów



W tej części zastosowano metodę **PELT** (*Pruned Exact Linear Time*) do wykrywania **zmian strukturalnych** w szeregu – tj. momentów, w których następuje istotna zmiana **średniego poziomu** i/lub **wariancji**. Zgodnie z teorią, obecność takich punktów oznacza, że szereg nie jest jednorodny w całym horyzoncie i można go traktować jako sekwencję kolejnych „reżimów” o innych parametrach.

Tabela i pionowe linie na wykresie pokazują daty wykrytych punktów zmiany (m.in. 2005–2007, 2009–2011 oraz kolejne w latach 2013–2016; w dalszej części szeregu analogicznie pojawiają się następne punkty aż do okresu prognozy). Ich rozmieszczenie jest spójne z obserwacją, że cena złota przechodziła przez fazy dynamicznych wzrostów, okresy korekty oraz ponownego przyspieszenia, co przekłada się na zmianę poziomu i zmienności. W praktyce oznacza to, że modele o stałych parametrach dopasowane do całego okresu mogą mieć trudność w dokładnym odwzorowaniu końcowych fragmentów danych (zwłaszcza przy gwałtownych zmianach reżimu), dlatego w projekcie uzasadnione jest: (1) stosowanie transformacji stabilizujących (np. Box–Cox), (2) ocena modeli na wydzielonym zbiorze testowym oraz (3) interpretowanie prognoz z uwzględnieniem rosnącej niepewności w okresach przejściowych.

Podsumowanie analizy złota

Analiza miesięcznych cen złota wskazuje na **silny, nieliniowy trend długookresowy** oraz wyraźne fazy wzrostów i korekt, natomiast **sezonowość miesięczna jest słaba/drugorzędna** (zmiany między latami dominują nad różnicami między miesiącami). Testy stacjonarności potwierdziły, że **$\log(\text{cena})$ pozostaje niestacjonarna** (ADF: brak odrzucenia unit root; KPSS: odrzucenie stacjonarności), natomiast **$\text{diff}(\log(\text{cena}))$ jest stacjonarna** (ADF: odrzucenie unit root; KPSS: brak odrzucenia stacjonarności), co uzasadnia podejście z różnicowaniem w modelach ARIMA / pracę na log-zwrotach. W porównaniu modeli prognostycznych na zbiorze testowym ($h = 12$) najlepsze wyniki uzyskał **ARIMA z transformacją Box–Cox** (najniższe RMSE/MAE/MAPE), podczas gdy ETS/ARIMA bez transformacji oraz benchmark DRIFT dawały zbliżone, słabsze rezultaty, a NAIVE był najslabszy; dlatego ARIMA(BoxCox) przyjęto jako model finalny także do prognozy 24-miesięcznej (z rosnącą niepewnością wraz z horyzontem). Dodatkowo wykryto **zmiany strukturalne** (PELT: średnia i wariancja) – szereg przechodzi przez kolejne reżimy, co tłumaczy trudność prostych modeli w końcówce próby i jest ważnym kontekstem interpretacji prognoz (szczególnie w okolicach dużych przejść reżimowych, np. ~2008 i ~2020).

Analiza szeregu czasowego dla miesięcznej ceny uncji srebra


Analiza szeregu czasowego dla miesięcznej ceny uncji miedzi

Pytania badawcze

1. Czy szereg wykazuje trend lub sezonowość?
2. Czy po transformacji (log, różnice) szereg jest stacjonarny?
3. Który model (ETS/ARIMA/baseline) daje najlepszą prognozę na 12–24 miesiące?
4. Czy w danych występują zmiany strukturalne?

EDA: wykres, rozkład, outliersy

Szereg cen miedzi wykazuje inną charakterystykę niż złoto. Miedź jest metalem ściśle przemysłowym, dlatego jej cena silnie reaguje na cykle koniunkturalne, pełniąc rolę barometru globalnej gospodarki.




W przeciwieństwie do złota, które często rośnie w czasie niepokoїв jako “bezpieczna przystań”, miedź wykazuje większą zmienność cykliczną, podążając za tempem globalnego wzrostu PKB.

Gwałtowny spadek (2008/2009): Reakcja na Globalny Kryzys Finansowy i załamanie popytu inwestycyjnego.

Trend spadkowy (2011–2016): Wynikał ze spowolnienia gospodarczego w Chinach (największego konsumenta miedzi) oraz nadpodaży surowca po okresie inwestycyjnym (“koniec supercyklu surowcowego”).

Szok COVID-19 (2020): Krótkotrwale załamanie, po którym nastąpiło dynamiczne odbicie wywołane stymulacją fiskalną i zaburzeniami łańcuchów dostaw.


Okres niepewności (2022–obecnie): Wybuch wojny w Ukrainie początkowo wywindował ceny (obawy o podaż), jednak w drugiej połowie 2022 roku nastąpiła korekta spowodowana podwyżkami stóp procentowych (walka z inflacją) oraz polityką “Zero-COVID” w Chinach. Obecnie obserwujemy *trend boczny* - rynek balansuje między obawami o recesję a rosnącym popytem ze strony sektora transformacji energetycznej (OZE, samochody elektryczne).



Rozkład cen miedzi w badanym okresie jest jednomodalny (posiada jedno główne maksimum), z najsilniejszą koncentracją obserwacji w przedziale 0.20–0.25 USD/oz. Wskazuje to, że mimo licznych wahań koniunkturalnych, rynek miedzi najczęściej dążył do równowagi w tym właśnie zakresie cenowym.

W przeciwieństwie do złota, którego rozkład charakteryzował się silną asymetrią prawostronną (długi ogon oznaczający ucieczkę cen w górę), rozkład miedzi jest bardziej symetryczny, lecz szeroki (duża dyspersja). Oznacza to, że miedź jest aktywem o wysokiej zmienności w obie strony – ceny potrafią dynamicznie rosnąć w czasie boomu, ale też głęboko spadać w czasie recesji, rzadko jednak wybijając się trwale na ekstremalnie wysokie poziomy bez późniejszej korekty.

Heatmapa cen miedzi: miesiąc vs rok




Podobnie jak w przypadku złota, mapa ciepła dla miedzi wskazuje na dominację zmian między latami (poziome pasy) nad zmianami wewnątrz roku (sezonowość miesięczna). Wyraźnie widać „ciemne pasy” w latach boomu surowcowego (ok. 2011 oraz po 2020 r.) oraz „jasne obszary” odpowiadające niższym poziomom cenowym: na początku badanego okresu (2005) oraz w latach spowolnienia gospodarczego (koniec 2008/2009, 2015/2016). Brak wyraźnych pionowych pasów sugeruje, że sezonowość kalendarzowa (np. wzrosty zawsze w marcu) jest słabsza niż wpływ globalnych trendów makroekonomicznych.

Dekompozycja szeregu

Przeprowadzono dekompozycję szeregu czasowego metodą STL, wyodrębniając składową trendu, sezonowości oraz reszt.

Dekompozycja cen miedzi (STL)



Dominacja Trendu i Cyklu: Głównym czynnikiem kształtującym cenę miedzi jest składowa trendu (panel trend). Nie jest ona liniowa, lecz wykazuje silną cykliczność, z wyraźnymi załamaniem w okresach recesji (2008, 2020). Potwierdza to, że miedź jest surowcem wrażliwym na koniunkturę gospodarczą.


Marginalna Sezonowość: Panel seasonal wskazuje na istnienie powtarzalnego wzorca rocznego, jednak jego siła jest znikoma. Analizując szare paski skali, widzimy, że wahania sezonowe mają amplitudę rzędu ~ 0.008 USD/oz, co stanowi ułamek wartości surowca (ok. 2-3% ceny). Oznacza to, że choć matematycznie można wyodrębnić pewną sezonowość, to ekonomicznie jest ona zagłuszana przez silne zmiany trendu i szoki rynkowe.

Trend: aproksymacja wielomianowa


Przyjęto maksymalny stopień wielomianu równy 12, analogicznie do analizy złota. Choć kryterium AIC sugeruje dalszy spadek wartości dla wyższych stopni, ograniczenie to wynika z chęci uniknięcia nadmiernego dopasowania oraz braku ekonomicznego uzasadnienia dla stosowania wielomianów tak wysokiego rzędu do opisu cykli surowcowych.

Mimo zastosowania wielomianu wysokiego stopnia (12), dopasowana krzywa nie oddaje precyzyjnie dynamiki cen miedzi. Przebieg trendu wielomianowego jest z natury zbyt „gładki” i łagodny, przez co model „ścina” ostre punkty zwrotne (głębokie dolki kryzysowe w 2008 i 2020 roku oraz gwałtowne szczyty). Wskazuje to, że sztywna funkcja matematyczna nie jest w stanie w pełni odwzorować złożonej, ostrej cykliczności surowca, co uzasadnia przejście do bardziej elastycznych metod wygładzania (MA, EWMA).

Dobór stopnia wielomianu trendu (AIC)




Trend wielomianowy miedzi (stopień 12)



Wygładzanie: MA i EWMA

Zastosowano dwie metody wygładzania szeregu: prostą średnią ruchomą MA(12) oraz średnią wykładniczą EWMA.

Wygładzanie cen miedzi



Analiza wykresu pokazuje, że obie metody radzą sobie z opisem trendu znacznie lepiej niż sztywny model wielomianowy, poprawnie podążając za cyklicznymi zwrotami cen. Warto jednak zauważyć przewagę metody EWMA (linia brązowa), która dzięki mechanizmowi wykładniczych wag szybciej reaguje na gwałtowne zmiany rynkowe (np. odbicie po COVID-19 w 2020 r.) i ściślej przylega do rzeczywistego przebiegu cen. Metoda MA(12) (linia czarna), choć skutecznie eliminuje szum, wykazuje zauważalne opóźnienie (efekt inercji) w punktach zwrotnych, co jest naturalną cechą średnich arytmetycznych o stałych wagach.

Stacjonarność i transformacje

```
[1] "ADF dla log(ceny):"
```

Augmented Dickey-Fuller Test

```
data: na.omit(copper$log_price)
Dickey-Fuller = -3.4627, Lag order = 6, p-value = 0.04701
alternative hypothesis: stationary
```

```
[1] "ADF dla zwrotów (diff log):"
```

Augmented Dickey-Fuller Test

```
data: na.omit(copper$dlog_price)
Dickey-Fuller = -6.0748, Lag order = 6, p-value = 0.01
alternative hypothesis: stationary
```

Wynik testu dla **logarytmu cen** jest niejednoznaczny. P-value wynosi 0.047, co jest wartością graniczną (tuż poniżej progu 0.05). Formalnie sugerowałoby to stacjonarność wokół trendu (trend deterministyczny), jednak wizualna ocena wykresu i charakter danych giełdowych wskazują na niestacjonarność.

Natomiast dla **pierwszych różnic (log-zwrotów)** test daje bardzo silny wynik ($p < 0.01$), co jednoznacznie potwierdza stacjonarność. Dlatego, mimo granicznego wyniku dla poziomów, w dalszym modelowaniu (ARIMA) traktujemy proces jako niestacjonarny (z trendem stochastycznym) i wymagający różnicowania. Oznacza to, że przyszła cena zależy od skumulowanych, losowych szoków rynkowych, a nie tylko od upływu czasu.

Modelowanie i prognoza (Train 2005-2023 / Test 2024)


Porównanie metryczne

```
# A tibble: 6 x 3
  model      RMSE  MAPE
  <chr>    <dbl> <dbl>
1 ARIMA (BoxCox) 0.0216  5.74
2 ARIMA         0.0224  6.43
3 DRIFT         0.0237  6.57
4 ETS           0.0255  7.31
5 ETS (BoxCox)  0.0274  7.89
6 NAIVE         0.0278  8.06
```

Najlepsze wyniki prognostyczne na zbiorze testowym osiągnął model **ARIMA z transformacją Boxa-Coxa**, uzyskując najniższy błąd RMSE (0.0216) oraz MAPE (5.74%). Wynik ten potwierdza wcześniejsze wnioski z analizy EDA – miedź charakteryzuje się zmienną wariancją (amplituda wahań zależy od poziomu cen), dlatego zastosowanie transformacji stabilizującej (Box-Cox) pozwoliło na lepsze dopasowanie modelu niż w przypadku klasycznej ARIMY czy modeli wykładniczych (ETS). Słabszy wynik modelu NAIVE (ostatnie miejsce) świadczy o tym, że w danych występuje struktura (autokorelacja/trend), którą modele zaawansowane potrafiły wykorzystać.

Porównanie wizualne

Prognozy cen miedzi na rok 2024 (Test)



Analiza wizualna ujawnia istotne wyzwanie w prognozowaniu cen surowców. Mimo że model ARIMA (BoxCox) (przerywana linia brązowa) osiągnął najmniejszy błąd średni, jego prognoza ma charakter zachowawczy - wyznacza "ścieżkę środka", wokół której oscyluje rzeczywista cena.


Rzeczywisty kurs miedzi w 2024 roku (ciągła linia) wykazał silną zmienność (gwałtowny skok w pierwszej połowie roku i późniejszą korektę), której modele statystyczne oparte na historii nie były w stanie precyzyjnie odwzorować co do kształtu. Jest to zjawisko typowe dla szeregów surowcowych, gdzie lokalne szoki (popytowe/podażowe) odchylają cenę od trendu długoterminowego. Mimo to, niski błąd MAPE (~5.7%) wskazuje, że model poprawnie określił przeciętny poziom cen w badanym okresie.

Finalna prognoza 24 miesiące do przodu

Prognozę na kolejne 24 miesiące wygenerowano przy użyciu najlepszego modelu: ARIMA z transformacją Boxa-Coxa.

Model sugeruje, że choć najbardziej prawdopodobnym scenariuszem jest utrzymanie obecnych poziomów cenowych, rynek miedzi pozostaje obciążony gigantycznym ryzykiem. W perspektywie 2 lat cena z 95-procentowym prawdopodobieństwem może znaleźć się w przedziale od kryzysowych 0.15 USD do rekordowych 0.40 USD. Oznacza to, że przyszłość rynku zależy nie od trendu technicznego, lecz od nadchodzących impulsów fundamentalnych (np. tempo transformacji energetycznej vs. globalna recesja).

Prognoza ceny miedzi (2025–2026)



Scenariusz centralny (linia ciągła): Model przewiduje stabilizację cen na poziomie zbliżonym do obecnego (ok. 0.27–0.28 USD/oz). Płaski przebieg prognozy punktowej wynika z natury procesów stochastycznych typu random walk – najlepszą prognozą przyszłej ceny jest jej ostatnia znana wartość (skorygowana o parametry modelu). Kluczową informacją są bardzo **szerokie przedziały ufności (80% i 95%)**. Rozszerzają się one dynamicznie wraz z upływem czasu, co jest efektem zastosowania transformacji Boxa-Coxa (uwzględniającej zmienną wariancję) oraz historycznie dużej zmienności miedzi.

Zmiany strukturalne (PELT)

Wykrywanie zmian strukturalnych (PELT): średnia i wariancja



Metoda PELT (czerwona linia schodkowa) wykryła w szeregu czasowym istotne zmiany strukturalne. Wykres wyraźnie dzieli historię notowań na kilka odrębnych „reżimów”, w których średni poziom cen oraz ich wariancja były różne.

Kluczowe punkty zwrotne wykryte przez algorytm pokrywają się z najważniejszymi wydarzeniami makroekonomicznymi:

- Gwałtowny spadek: Odpowiada załamaniu podczas Globalnego Kryzysu Finansowego (2008/2009).
- Wzrost poziomu: To okres boomu surowcowego i odbicia w Chinach (2011).
- Skokowa zmiana w górę: Reakcja rynków na post-pandemiczną stymulację i inflację po roku 2020.

Wynik ten stanowi ostateczne potwierdzenie, że parametry generujące proces cenowy nie są stałe w czasie. Występowanie tak silnych zmian strukturalnych jest koronnym argumentem przeciwko stosowaniu prostych modeli liniowych na całej 20-letniej próbie i w pełni uzasadnia konieczność stosowania modeli adaptacyjnych (takich jak użyta wcześniej ARIMA z transformacją Boxa-Coxa), które potrafią dostosować się do zmieniającej się zmienności rynku.

Podsumowanie analizy miedzi

Analiza miesięcznych cen miedzi wskazuje na silną naturę cykliczną surowca (naprzemienne okresy boomu i recesji skorelowane z koniunkturą gospodarczą), przy czym sezonowość miesięczna jest marginalna i ekonomicznie pomijalna w porównaniu do składowej trendu. Testy stacjonarności dały wynik graniczny dla $\log(\text{cena})$ (p-value ≈ 0.047), jednak ze względu na charakter danych giełdowych oraz jednoznaczny wynik dla $\text{diff}(\log(\text{cena}))$ (silne odrzucenie hipotezy o niestacjonarności), szereg modelowano jako proces zintegrowany $I(1)$. W porównaniu modeli prognostycznych na zbiorze testowym ($h = 12$, rok 2024) najlepsze wyniki uzyskał model ARIMA z transformacją Box-Cox (najniższe RMSE i MAPE). Zastosowanie tej transformacji było kluczowe ze względu na zmienną wariancję (amplituda wahań rośnie wraz z poziomem cen). Model ten pokonał proste benchmarki (NAIVE, DRIFT), co potwierdza istnienie struktury zależności możliwej do prognozowania, mimo trudnego rynku w 2024 roku. Finalna prognoza 24-miesięczna wskazuje na stabilizację poziomu cen (zachowawczy charakter modelu), ale obciążona jest **ogromną niepewnością** (bardzo szerokie przedziały ufności). Analiza zmian strukturalnych (PELT) potwierdziła występowanie **odrębnych reżimów zmienności**, pokrywających się z kluczowymi szokami makroekonomicznymi (2008, 2011, 2020), co tłumaczy wyższość metod adaptacyjnych (EWMA, ARIMA) nad sztywnymi trendami deterministycznymi.

Podsumowanie

zrobi to osoba która będzie swoją część projektu robiła jako ostatnia, summary z rzeczy opisanych przez wszystkie osoby