

Projekt Szeregi Czasowe

Diana Morzhak, Mateusz Walo, Dominika Zydorczyk

Cel i zarys projektu

Celem niniejszego projektu jest przeanalizowanie danych dotyczących miesięcznej ceny takich metali szlachetnych jak złoto, miedź oraz srebro wyrażonej w dolarach amerykańskich w okresie lat 2005 - 2025 za 1 uncję takiego metalu. Okres ten obejmuje 20 lat które gospodarczo i ekonomicznie miały bardzo wiele wydarzeń które miały wpływ na wachanie się ceny tego jakże cennego surowca. W ciągu tych 20 lat mieliśmy doczynienia z pandemią COVID-19, wybuchem wojny na Ukrainie oraz ekspansją rozwoju sztucznej inteligencji, bardzo ciekawe czasu :)

Dlaczego akurat metale szlachetne? Jest to surowiec który wykorzystywano jeszcze zanim powstała waluta dolara amerykańskiego, i ten surowiec jest niezwykle ważny dla globalnej gospodarki.

Dane dotyczące złota zostały pobrane przez API Pythonowe z witryny <https://freegoldapi.com/data/latest.csv> i odpowiednio sformatowane tak aby plik z danymi nadawał się do dalszej analizy, skrypty pythonowe użyte do pobrania i obróbki danych znajdują się w repozytorium w folderze `utils/`

Dane o cenach srebra zostały pobrane z serwisu [stooq.pl](https://www.stooq.pl) w postaci dziennych notowań USD/oz. Po konwersji dat do formatu czasowego oraz cen do typu numerycznego dane zostały zagregowane do średnich miesięcznych, a następnie ograniczone do okresu 2005–2025.

Dane o cenach miedzi natomiast pochodzą z bazy FRED (Federal Reserve Economic Data) i zostały pobrane już w ujęciu miesięcznym. Ceny wyrażone pierwotnie w USD za tonę metryczną zostały przeliczone na USD za uncję trojańską, aby zachować spójność jednostek z pozostałymi danymi.

Przedstawienie danych wszystkich metali


zrobi tą część osoba która będzie robiła swoją część jako ostatnia i tutaj wykresiki wszystkich trzech metali jednocześnie, z zaznaczeniem ważnych dat - covid, wojna etc. to taki dalszy wstęp jeszcze przed tym czy wgl zajmiemy się na poważnie szeregami :)

Analiza szeregu czasowego dla miesięcznej ceny uncji złota

Pytania badawcze


1. Czy szereg wykazuje trend lub sezonowość?
2. Czy po transformacji (log, różnice) szereg jest stacjonarny?
3. Który model (ETS/ARIMA/baseline) daje najlepszą prognozę na 12–24 miesiące?
4. Czy w danych występują zmiany strukturalne (np. okolice 2008, 2020)?

Złoto: miesięczna cena (USD/oz), 2005...2025



Szereg miesięcznych cen złota w USD w latach 2005–2025 wykazuje wyraźny długookresowy trend wzrostowy, ale nie jest to wzrost jednolity w czasie. W danych widać co najmniej kilka faz (reżimów): silny wzrost do okolic 2011–2012, następnie kilkuletnie osłabienie i stabilizacja, ponowny wzrost w latach 2019–2021 oraz bardzo dynamiczne przyspieszenie w końcowej części próby (2024–2025), gdzie ceny osiągają nowe maksima. Zmienność także wydaje się rosnąć wraz z poziomem cen, co sugeruje niestacjonarność szeregu na poziomach i potencjalną potrzebę transformacji (np. logarytmowania) oraz analizy różnic/log-zwrotów. Już na etapie EDA można też podejrzewać występowanie zmian strukturalnych, dlatego w dalszej części projektu oprócz klasycznych modeli (ETS/ARIMA) zostanie sprawdzona stabilność w czasie oraz jakość prognoz na wydzielonym zbiorze testowym.


Rozkład cen złota (miesięcznie)



Rozkład miesięcznych cen złota jest wyraźnie prawostronnie asymetryczny: większość obserwacji koncentruje się w niższych przedziałach cenowych, a długi ogon po prawej stronie wynika z relatywnie krótkiego, ale bardzo wysokiego poziomu cen

w końcowej części próby. Taki kształt rozkładu jest typowy dla danych ekonomicznych mierzonych w poziomach i sugeruje, że wariancja może zależeć od poziomu (efekt skali).

Heatmapa cen: miesi..c vs rok




Heatmapa cen w układzie miesiąc-rok pozwala jednocześnie ocenić dwa aspekty szeregów czasowych **sezonowość** (wzorce powtarzające się w kolumnach miesięcy) oraz **zmiany poziomu** w czasie (różnice między wierszami lat). W przedstawionych danych nie widać stabilnego, powtarzalnego wzorca miesięcznego - kolory w obrębie pojedynczego roku są zwykle do siebie zbliżone, a ewentualne różnice między miesiącami są małe w porównaniu do zmian między latami. To sugeruje, że klasyczna sezonowość kalendarzowa (miesięczna) jest słaba lub drugorzędna. Jednocześnie wyraźnie widać **zmianę reżimów cenowych**: lata 2005–2007 są relatywnie „jasne”, okres ok. 2010–2012 jest zauważalnie „ciemniejszy”, następnie następuje kilkuletnia stabilizacja na umiarkowanym poziomie, a od okolic 2020 widać przejście do wyraźnie wyższych poziomów, z najsilniejszym przyciemnieniem w latach 2024–2025. Z punktu widzenia modelowania oznacza to, że w danych dominują zmiany poziomu w czasie, a komponent sezonowy – jeśli w ogóle występuje – nie jest kluczowy, co uzasadnia skupienie się na transformacjach/stacjonarności oraz modelach dobrze radzących sobie ze zmianami poziomu.

Trend: aproksymacja wielomianowa + wybór stopnia

Wybór stopnia wielomianu


Dobór stopnia wielomianu trendu (AIC)



Zgodnie z podejściem wykładowym, stopień wielomianu trendu dobrano na podstawie kryterium informacyjnego Akaikiego **AIC**, które równoważy jakość dopasowania z karą za złożoność modelu. Wraz ze wzrostem stopnia wielomianu AIC systematycznie maleje, co oznacza, że prostsze trendy (stopnie 1–3) nie oddają w pełni nieliniowego charakteru zmian cen w czasie. Minimum AIC uzyskano dla stopnia **11** (zaznaczone na wykresie), dlatego ten wariant przyjęto jako najlepszy kompromis między dopasowaniem a liczbą parametrów w ramach rozważanej rodziny modeli. Jednocześnie spłaszczenie krzywej AIC dla wysokich stopni sugeruje, że poprawa dopasowania po przekroczeniu okolic 7–8 jest już relatywnie niewielka, co w praktyce może oznaczać ryzyko „dopasowania się” do lokalnych wahań. Z tego powodu trend wielomianowy traktujemy przede wszystkim jako narzędzie opisu deterministycznej składowej.

Dopasowanie trendu do reszty


Trend wielomianowy (stopień.. 11)



Dopasowana krzywa dobrze oddaje **nieliniowy przebieg długookresowych zmian** (wzrost do ok. 2011–2012, spadek/stabilizacja w kolejnych latach oraz silne przyspieszenie po 2020), traktując krótkookresowe wahania jako składnik

Wyglądanie: MA i EWMA

Wyglądanie: MA(12) i EWMA



Na wykresie zastosowano dwie klasyczne metody wygładzania: **MA(12)** oraz **EWMA**.

MA(12) (*Moving Average*, 12-miesięczna średnia ruchoma) polega na zastąpieniu obserwacji średnią z ostatnich (lub – jak tu – z okna obejmującego) **12 miesięcy**, co silnie redukuje wahania krótkookresowe i wydobywa **trend/cykl w skali rocznej**. Skutkiem ubocznym jest **opóźnienie (lag)** względem szeregu – MA reaguje wolniej na nagłe zmiany, bo każda nowa obserwacja wpływa na wynik tylko w $1/12$.

EWMA (*Exponentially Weighted Moving Average*, wykładniczo ważona średnia ruchoma) nadaje obserwacjom w przeszłości **malejące wykładniczo wagi**. Formalna definicja ma postać

$$y_t = \lambda x_t + (1 - \lambda) \cdot y_{t-1}$$


Parametr $\lambda = 0.2$ oznacza, że bieżąca obserwacja ma 20% wagi, a pozostałe 80% “dziedziczone” jest z poprzedniego wygładzenia. W praktyce EWMA jest **bardziej responsywna** niż MA i szybciej “podąża” za zmianami trendu, jednocześnie tłumiąc szum.

Interpretując wynik: obie krzywe wygładzające potwierdzają nieliniowy przebieg długookresowy – wzrost do ok. 2011–2012, późniejsze osłabienie/stabilizację oraz ponowne przyspieszenie po 2019–2020. W końcowej części próby (ok. 2024–2025) widać gwałtowne zwiększenie tempa wzrostu ceny: **EWMA reaguje na to szybciej**, natomiast **MA(12)** pozostaje bardziej “inercyjna” i wygładza tę zmianę mocniej, przez co jej linia jest bardziej opóźniona. Z punktu widzenia projektu, te metody pełnią rolę opisową: pokazują strukturę trendu i skalę wahań krótkookresowych.

Stacjonarność i transformacje

Logarytmowanie i różnicowanie

Transformacje szeregu: log i różnicowanie loga



Testy ADF

Przed budową modeli stochastycznych często stosuje się transformacje, których celem jest **stabilizacja wariancji** i doprowadzenie szeregu do postaci bliższej **stacjonarnej**. W tym celu wykorzystano dwie standardowe operacje:

1. **Transformacja logarytmiczna** $\log(P_t)$ – zmniejsza wpływ skali (duże wartości nie dominują tak silnie jak w poziomach), a w praktyce często stabilizuje rozrzut i ułatwia interpretację zmian w kategoriach względnych.
2. **Różnicowanie logarytmu** $\Delta \log(P_t) = \log(P_t) - \log(P_{t-1})$ usuwa trend deterministyczny/stochastyczny i w przybliżeniu odpowiada **procentowej stopie zwrotu** (log-zwrotowi). To jedna z najczęściej stosowanych transformacji w analizie finansowej i klasycznym modelowaniu ARIMA, gdy poziomy cen wykazują niestacjonarność.

Interpretacja wykresu:

panel z **log(cena)** nadal pokazuje długookresowy wzorec (wzrost do ok. 2011–2012, spadek/stabilizacja, a następnie silne przyspieszenie w końcówce próby), czyli sama transformacja logarytmiczna **nie usuwa trendu**, tylko zmienia skalę i „uspokaja” względne różnice.

Natomiast panel z **diff(log(cena))** oscyluje wokół zera i nie wykazuje trwałego trendu, co sugeruje, że różnicowanie logarytmu skutecznie eliminuje komponent długookresowy i daje serię bardziej odpowiednią do dalszych testów stacjonarności oraz identyfikacji struktury zależności (ACF/PACF). Jednocześnie widoczne są okresy większej i mniejszej amplitudy wahań, co wskazuje na zmienność zmieniającą się w czasie.

Testy ADF

ADF - Augmented Dickey - Fuller test

Test ADF służy do sprawdzania, czy szereg ma **pierwiastek jednostkowy**, czyli czy jest **niestacjonarny** w sensie klasycznym (np. zachowuje się jak random walk z trendem). „Augmented” oznacza, że do równania dodaje się opóźnienia (lag order), by usunąć autokorelację reszt.

- **Hipoteza zerowa H_0** : szereg jest **niestacjonarny** (ma pierwiastek jednostkowy).
- **Hipoteza alternatywna H_1** : szereg jest **stacjonarny**.

KPSS - Kwiatkowski - Phillips - Schmidt - Shin

KPSS jest komplementarny do ADF: sprawdza stacjonarność „od drugiej strony”.

- Hipoteza zerowa **H0**: szereg jest **stacjonarny**
- Hipoteza alternatywna **H1**: szereg jest **niestacjonarny**.

Augmented Dickey-Fuller Test

```
data: na.omit(gold$log_price)
Dickey-Fuller = -1.7675, Lag order = 6, p-value = 0.6737
alternative hypothesis: stationary
```

Wniosek: p-value jest bardzo duże, więc **nie mamy podstaw aby odrzucić H_0** . To oznacza, że **log(cena)** nadal zachowuje się jak szereg **niestacjonarny** (ma trend / składową losową typu random walk). Sama transformacja logarytmiczna stabilizuje skalę, ale **nie usuwa niestacjonarności poziomów**.

Augmented Dickey-Fuller Test

```
data: na.omit(gold$dlog_price)
Dickey-Fuller = -4.7958, Lag order = 6, p-value = 0.01
alternative hypothesis: stationary
```

Wniosek: p-value jest bardzo małe, więc **odrzucaamy H_0** . Oznacza to, że **różnice logarytmów (log-zwroty)** są **stacjonarne** (przynajmniej w sensie ADF). To klasyczny rezultat dla danych finansowych: poziomy są niestacjonarne, a przyrosty/log-zwroty są bliższe stacjonarności.

KPSS Test for Level Stationarity



```
data: na.omit(gold$log_price)
KPSS Level = 3.0892, Truncation lag parameter = 5, p-value = 0.01
```

Wniosek: p-value jest małe, więc **odrzucaamy H_0 o stacjonarności poziomym**. Czyli KPSS potwierdza, że **log(cena)** jest **niestacjonarna**. Wskazuje na spójność z ADF na log_price oba testy wskazują **niestacjonarność**.

KPSS Test for Level Stationarity

```
data: na.omit(gold$dlog_price)
KPSS Level = 0.26519, Truncation lag parameter = 5, p-value = 0.1
```

ACF/PACF

ACF: diff(log(cena))**PACF: diff(log(cena))****Diagnostyka reszt trendu****Losowość**

Runs Test

```
data: na.omit(reszty)
statistic = -10.478, runs = 44, n1 = 126, n2 = 126, n = 252, p-value <
2.2e-16
alternative hypothesis: nonrandomness
```

Test serii (Runs Test) sprawdza, czy znaki reszt pojawiają się w sposób losowy (H_0 : losowość). Otrzymano **p-value < 2.2e-16**, więc zdecydowanie **odrzucaamy hipotezę o losowości**.

Wniosek: reszty po odjęciu trendu wielomianowego wykazują **uporządkowanie/strukturę**, co sugeruje, że sam trend deterministyczny nie opisuje w pełni dynamiki szeregu i w danych pozostają zależności czasowe wymagające modelowania stochastycznego.

Autokorelacja reszt

Box-Ljung test

```
data: na.omit(reszty)
X-squared = 718.76, df = 24, p-value < 2.2e-16
```

Test Boxa-Ljunga weryfikuje hipotezę H_0 , że reszty są **nieautokorelacyjne** (biały szum) do zadanego rzędu opóźnień (tu: 24). Ponieważ **p-value < 2.2e-16**, zdecydowanie **odrzucaamy H_0** . Oznacza to, że w resztach po usunięciu trendu nadal występuje istotna **autokorelacja**, więc trend wielomianowy nie wystarcza – potrzebny jest model uwzględniający zależności czasowe albo dodatkowe składowe strukturalne.

Normalność

Shapiro-Wilk normality test

```
data: sample(na.omit(reszty), min(5000, length(na.omit(reszty))))  
W = 0.9923, p-value = 0.2141
```

Jarque-Bera Normality Test

```
data: na.omit(reszty)  
JB = 2.9561, p-value = 0.2281  
alternative hypothesis: greater
```

Oba testy badają zgodność rozkładu reszt z rozkładem normalnym (H_0 : normalność). Dla Shapiro-Wilka otrzymano **p-value = 0.214**, a dla Jarque-Bera **p-value = 0.228**, więc w obu przypadkach **brak podstaw do odrzucenia normalności** reszt na typowych poziomach istotności. W praktyce oznacza to, że kształt rozkładu reszt nie odbiega istotnie od normalnego; jednocześnie wcześniejsze testy (Runs i Ljung-Box) pokazują, że problemem reszt nie jest rozkład, tylko **zależności czasowe**, które wymagają modelowania.

Heteroskedastyczność


studentized Breusch-Pagan test

```
data: reszty ~ t  
BP = 4.0428, df = 1, p-value = 0.04436
```

Goldfeld-Quandt test

```
data: reszty ~ t  
GQ = 1.318, df1 = 124, df2 = 124, p-value = 0.06277  
alternative hypothesis: variance increases from segment 1 to 2
```

Testy te sprawdzają, czy wariancja reszt jest stała w czasie (H_0 : homoskedastyczność). W teście **Breuscha-Pagana** otrzymano **p-value = 0.044**, co oznacza odrzucenie H_0 na poziomie 0.05 i sugeruje **niejednorodną wariancję** (zmiennność reszt zależną od czasu/trendu). Z kolei **Goldfeld-Quandt** daje **p-value = 0.063**, czyli wynik graniczny: na poziomie 0.05 nie odrzucamy H_0 , ale na 0.1 pojawia się sygnał, że wariancja może rosnąć w późniejszym okresie (zgodnie z hipotezą alternatywną o wzroście wariancji). Łącznie wskazuje to, że w resztach może występować umiarkowana heteroskedastyczność, co uzasadnia transformacje (np. log) i ostrożność w założeniu stałej wariancji przy dalszym modelowaniu.



Modelowanie i prognoza

Podział na train/test

W celu obiektywnej oceny jakości prognoz zastosowano podział na **zbiór uczący (train)** i **zbiór testowy (test)** zgodnie z podejściem z wykładu. Ostatnie **12 miesięcy** ($h = 12$) wydzielono jako test, aby sprawdzić, jak modele radzą sobie z prognozowaniem „w przyszłość” na nieznanymi danych. Następnie oba zbiory przekształcono do obiektu typu **ts** sz częstotliwością **12** (dane miesięczne), co umożliwia wykorzystanie metod prognozowania (np. ETS/ARIMA) oraz porównanie prognoz i metryk błędu na jednolitej osi czasu.

Baseline: naive i drift

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	9.305356	49.62299	37.77741	0.6945365	2.931205	0.2141852
Test set	791.992051	923.31462	791.99205	21.5833992	21.583399	4.4903277
ACF1 Theil's U						
Training set	0.2188519	NA				
Test set	0.6956772	4.805866				

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-3.353931e-14	48.74271	37.69181	-0.1236883	2.922483	0.2136999
Test set	7.315072e+02	855.47152	731.50724	19.9172510	19.917251	4.1473992
ACF1 Theil's U						
Training set	0.2188519	NA				
Test set	0.6908275	4.447768				

Poniżej masz krótki, ale treściwy komentarz „wykładowy”: co to za modele benchmarkowe i co mówią Twoje wyniki.

Jako punkt odniesienia zastosowano dwa klasyczne modele.

NAIVE - (model naiwny) zakłada, że prognoza na wszystkie kolejne okresy jest równa **ostatniej obserwacji** ze zbioru uczącego (odpowiednik random walk bez dryfu).

DRIFT - to wariant random walk z **dryfem**, gdzie prognoza oprócz poziomu uwzględnia średnią zmianę w czasie (trend liniowy wynikający z historii). Takie benchmarki są ważne, bo dla szeregów finansowych często trudno je wyraźnie pobić i dopiero porównanie z nimi pokazuje realną wartość bardziej złożonych modeli.

Wyniki na zbiorze testowym (ostatnie 12 miesięcy) wskazują, że oba modele mają duży błąd, ale **DRIFT radzi sobie lepiej niż NAIVE**: RMSE spada z ok. **923** do **855**, a MAE z ok. **792** do **732**. Dodatkowo **ME** (ok. **792** dla NAIVE i **732** dla DRIFT) oznacza **systematyczne zaniżanie prognoz** względem rzeczywistych wartości w teście – testowy fragment szeregu znajduje się wyraźnie wyżej niż poziom „wyniesiony” z treningu. MAPE rzędu **~20–22%** potwierdza, że proste założenia o stałym poziomie (NAIVE) lub stałym tempie wzrostu (DRIFT) nie oddają dobrze dynamiki w ostatnim roku. Te wyniki uzasadniają przejście do modeli adaptacyjnych (ETS/ARIMA) oraz rozważenie transformacji (np. Box–Cox), aby lepiej uchwycić zmianę poziomu i skalę wahań

ETS i ARIMA

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	0.02287788	48.64457	37.53642	-0.1210868	2.910903	0.2128188
Test set	731.50329662	855.46743	731.50330	19.9171398	19.917140	4.1473769
ACF1 Theil's U						
Training set	0.2189265	NA				
Test set	0.6908273	4.447746				

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	0.0117923	47.33331	36.58103	-0.09430785	2.855501	0.2074021
Test set	730.4281178	854.56100	730.42812	19.88520093	19.885201	4.1412810
ACF1 Theil's U						
Training set	-0.005889778	NA				
Test set	0.690831471	4.442572				

W kolejnym kroku zastosowano dwa podstawowe modele prognostyczne **ETS** oraz **ARIMA**.

Model **ETS** (Error–Trend–Seasonal) opisuje szereg poprzez wygładzanie wykładnicze i dobór struktury błędu, trendu i sezonowości (automatycznie wybieranej na podstawie kryteriów informacyjnych).

Z kolei **ARIMA** (AutoRegressive Integrated Moving Average) modeluje zależności autokorelacyjne, a składnik *Integrated* odpowiada za różnicowanie (w praktyce kompensuje niestacjonarność poziomów); dodatkowo dopuszcza komponent sezonowy.

Na zbiorze testowym oba modele osiągają **bardzo podobne wyniki** i są praktycznie równoważne: dla ETS RMSE **855.47**, MAE **731.50**, a dla ARIMA RMSE **854.56**, MAE **730.43**. Oznacza to poprawę względem modelu naiwnego i porównywalny poziom do modelu z dryfem (DRIFT), ale bez wyraźnego przełomu jakości. Dodatkowo wartości **ME 730–731** wskazują, że również ETS i ARIMA **systematycznie zaniżają prognozy** w okresie testowym, co sugeruje, że ostatni rok danych ma wyraźnie wyższy poziom niż wynikałoby to z historii w zbiorze uczącym (zmiana reżimu / silny wzrost). W konsekwencji same modele ETS/ARIMA bez dodatkowych zabiegów (np. transformacji Box–Cox, czyszczenia outlierów lub uwzględnienia zmian strukturalnych) nie eliminują problemu biasu w testowym fragmencie szeregu.”

Modelowanie za pomocą transformacji Boxa-Coxa

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	2.833193	48.78596	37.33237	0.07491358	2.898549	0.211662
Test set	721.334150	844.44634	721.33415	19.63435883	19.634359	4.089721

ACF1 Theil's U

Training set	0.2083711	NA
Test set	0.6900627	4.388795

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-2.098183	47.627	37.23784	-0.1449164	2.895187	0.211126
Test set	630.613989	740.717	630.61399	17.1514423	17.151442	3.575369

ACF1 Theil's U

Training set	0.0692158	NA
Test set	0.6799652	3.845497

Porównanie metryczne modeli


A tibble: 6 x 4

model	RMSE	MAE	MAPE
<chr>	<dbl>	<dbl>	<dbl>
1 ARIMA (BoxCox)	741.	631.	17.2
2 ETS (BoxCox)	844.	721.	19.6
3 ARIMA	855.	730.	19.9
4 ETS	855.	732.	19.9
5 DRIFT	855.	732.	19.9
6 NAIVE	923.	792.	21.6

Porównanie wizualne modeli


Porównanie prognoz cen z..ota (USD/oz)

— ARIMA — DRIFT — ETS (BoxCox)
 — ARIMA (BoxCox) — ETS — NAIVE



Diagnostyka najlepszego modelu

Diagnostyka reszt



Ljung-Box test

```
data: Residuals from ARIMA(0,1,1) with drift
Q* = 20.144, df = 23, p-value = 0.6332
```


```
Model df: 1. Total lags used: 24
```

Zgodnie z podejściem omawianym na wykładzie, po wyborze najlepszego modelu prognozującego należy sprawdzić, czy jego reszty zachowują się jak **biały szum** – tzn. mają średnią bliską zeru, nie wykazują istotnej autokorelacji i nie zawierają systematycznej struktury, której model nie uchwycił. Funkcja `checkresiduals()` łączy w jednej diagnostyce: wykres reszt w czasie, histogram z przybliżeniem rozkładu oraz ACF reszt, a także wykonuje formalny test Ljunga–Boxa.

W teście **Box–Ljung** otrzymano **p-value = 0.6332** (dla 24 opóźnień), więc **brak podstaw do odrzucenia hipotezy zerowej o braku autokorelacji reszt**. Oznacza to, że model ARIMA(0,1,1) z dryfem skutecznie „wyczyścił” zależności liniowe w danych – reszty można traktować jako w przybliżeniu nieskorelowane, co jest kluczowym warunkiem poprawnej specyfikacji modelu.

Wizualnie (ACF i przebieg reszt) nie widać dominujących, systematycznych wzorców, a rozkład reszt jest zbliżony do symetrycznego, co dodatkowo wspiera wniosek, że model jest dobrze dopasowany do struktury średniej. Ewentualne pojedyncze przekroczenia na ACF mogą pojawiać się losowo przy wielu testowanych opóźnieniach i nie muszą oznaczać problemu, jeśli test globalny (Ljung–Box) nie wskazuje autokorelacji.”

Prognoza cen z..ota – model: ARIMA (BoxCoc



Finalna prognoza została wyznaczona modelem **ARIMA** z transformacją **Box–Cox**, w którym rozrzut rośnie wraz z poziomem cen. Model wskazuje na **kontynuację trendu wzrostowego** w horyzoncie 24 miesięcy, ale jednocześnie przedziały predykcji szybko się rozszerzają, co oznacza rosnącą **niepewność prognozy** wraz z wydłużaniem horyzontu (typowe dla modeli z różnicowaniem/losowym składnikiem trendu). Innymi słowy, ARIMA(BoxCox) sugeruje dalszy wzrost jako scenariusz centralny, lecz dopuszcza szeroki zakres możliwych ścieżek cen w przyszłości.


Zmiany strukturalne i zmienność

Zmiany strukturalne

```
# A tibble: 15 x 2
  changepoint_no date
  <int> <date>
1         1 2005-08-01
2         2 2006-03-01
3         3 2007-06-01
4         4 2007-08-01
5         5 2009-09-01
6         6 2010-09-01
7         7 2011-03-01
8         8 2013-04-01
9         9 2014-08-01
10        10 2016-02-01
11        11 2019-06-01
12        12 2020-03-01
13        13 2023-02-01
14        14 2024-02-01
15        15 2025-01-01
```

Wykrywanie zmian strukturalnych (PELT): ..r

Złota linia: cena ... Przerwane linie: wykryte punkty zmiany re...



W tej części zastosowano metodę **PELT** (*Pruned Exact Linear Time*) do wykrywania **zmian strukturalnych** w szeregu – tj. momentów, w których następuje istotna zmiana **średniego poziomu** i/lub **wariancji**. Zgodnie z teorią, obecność takich punktów oznacza, że szereg nie jest jednorodny w całym horyzoncie i można go traktować jako sekwencję kolejnych „reżimów” o innych parametrach.

Tabela i pionowe linie na wykresie pokazują daty wykrytych punktów zmiany (m.in. 2005–2007, 2009–2011 oraz kolejne w latach 2013–2016; w dalszej części szeregu analogicznie pojawiają się następne punkty aż do okresu prognozy). Ich rozmieszczenie jest spójne z obserwacją, że cena złota przechodziła przez fazy dynamicznych wzrostów, okresy korekty oraz ponownego przyspieszenia, co przekłada się na zmianę poziomu i zmienności. W praktyce oznacza to, że modele o stałych parametrach dopasowane do całego okresu mogą mieć trudność w dokładnym odwzorowaniu końcowych fragmentów danych (zwłaszcza przy gwałtownych zmianach reżimu), dlatego w projekcie uzasadnione jest: (1) stosowanie transformacji stabilizujących (np. Box–Cox), (2) ocena modeli na wydzielonym zbiorze testowym oraz (3) interpretowanie prognoz z uwzględnieniem rosnącej niepewności w okresach przejściowych.

Podsumowanie analizy złota

Analiza miesięcznych cen złota wskazuje na **silny, nieliniowy trend długookresowy** oraz wyraźne fazy wzrostów i korekt, natomiast **sezonowość miesięczna jest słaba/drugorzędna** (zmiany między latami dominują nad różnicami między miesiącami). Testy stacjonarności potwierdziły, że **$\log(\text{cena})$ pozostaje niestacjonarna** (ADF: brak odrzucenia unit root; KPSS: odrzucenie stacjonarności), natomiast **$\text{diff}(\log(\text{cena}))$ jest stacjonarna** (ADF: odrzucenie unit root; KPSS: brak odrzucenia stacjonarności), co uzasadnia podejście z różnicowaniem w modelach ARIMA / pracę na log-zwrotach. W porównaniu modeli prognostycznych na zbiorze testowym ($h = 12$) najlepsze wyniki uzyskał **ARIMA z transformacją Box–Cox** (najniższe RMSE/MAE/MAPE), podczas gdy ETS/ARIMA bez transformacji oraz benchmark DRIFT dawały zbliżone, słabsze rezultaty, a NAIVE był najsłabszy; dlatego ARIMA(BoxCox) przyjęto jako model finalny także do prognozy 24-miesięcznej (z rosnącą niepewnością wraz z horyzontem). Dodatkowo wykryto **zmiany strukturalne** (PELT: średnia i wariancja) – szereg przechodzi przez kolejne reżimy, co tłumaczy trudność prostych modeli w końcówce próby i jest ważnym kontekstem interpretacji prognoz (szczególnie w okolicach dużych przejść reżimowych, np. ~2008 i ~2020).

Analiza szeregu czasowego dla miesięcznej ceny uncji srebra

Eksploracja danych

Celem dalszej analizy jest identyfikacja struktury deterministycznej i stochastycznej miesięcznych cen srebra w latach 2005–2025 oraz dobór adekwatnego modelu probabilistycznego do opisu dynamiki rynku.




Szereg cen srebra charakteryzuje się trendem długookresowym oraz epizodami gwałtownych zmian poziomu (m.in. kryzys finansowy 2008, aprecjacji spekulacyjnej 2011, pandemia 2020). Już na etapie eksploracji widoczna jest niestacjonarność szeregu w średniej oraz brak stabilnych wahań o stałej amplitudzie.

Opisowa analiza trendu


1. Trend wielomianowy

Dobór stopnia wielomianu trendu (AIC)



Dobór stopnia wielomianu przeprowadzono na podstawie kryterium informacyjnego AIC. Minimalna wartość AIC uzyskana została dla wielomianu wysokiego stopnia, co wskazuje na zdolność modelu do dokładnego dopasowania danych, lecz jednocześnie rodzi ryzyko nadmiernego dopasowania (overfittingu).

Porównanie trendów wielomianowych




Wielomian 5. stopnia dostarcza gładkiej estymacji trendu długookresowego, dobrze oddając ogólny kierunek zmian cen srebra. Z kolei wielomian wysokiego stopnia (21) wykazuje nienaturalne oscylacje, próbując dopasować się do lokalnych fluktuacji losowych, co potwierdza jego skomplikowanie interpretacyjne. Wielomian 5. stopnia traktowany jest wyłącznie jako narzędzie opisowe.

2. Metoda ruchomych średnich i wykładniczych wag


Możemy również zauważyć, że EWMA lepiej oddaje charakter trendu niż MA, co potwierdza, że w analizowanym szeregu silny wpływ mają bieżące szoki i impulsy. Taki wpływ losowych fluktuacji na przyszłą cenę pozwala wysnuć przypuszczenie o istnieniu trendu stochastycznego w szeregu.

Wygładzanie: MA(12) i EWMA





Średnia ruchoma MA(12) interpretuje trend jako lokalny poziom cen w skali roku, przypisując jednakowe wagi ostatnim 12 obserwacjom i ignorując informacje wcześniejsze. Wykładnicze (EWMA) wykorzystuje pełną historię szeregu, przypisując obserwacjom wagi malejące wykładniczo. Parametr 0.78 dobrano tak, aby pamięć wykładniczego odpowiadała około 12 miesiącom, co umożliwia bezpośrednie porównanie z MA(12). Obie metody służą do identyfikacji trendu długookresowego, różniąc się jedynie szybkością reakcji na zmiany. EWMA reaguje płynniej i szybciej na szoki rynkowe, natomiast MA(12) tworzy bardziej „sztywną” estymację wartości ceny.

Analiza sezonowości i cykliczności. Dekompozycja szeregu



Dekompozycja klasyczna szeregu czasowego



Z powyższych wykresów możemy wnioskować, że sezonowość nie jest statystycznie istotna. Zmiana wartości ceny to zakres maks. 0.6 USD. Potwierdza to również brak wyraźnej sezonowości na wykresie z biblioteki `ggseasonplot`, ponieważ obserwujemy brak wahań fazowych na poziomie co 12 miesięcy. Wykresy szeregu oryginalnego i skorygowanego o sezonowość są niemal identyczne. Jest to dowód na to, że usunięcie komponentu sezonowego nie zmienia struktury informacji w szeregu, co oznacza, że sygnał główny to wyłącznie trend.

Na podstawie poniższych wzorów zaczerpniętych z pracy Wanga, Smitha i Hyndmana dotyczącej klasteryzacji szeregów czasowych w oparciu o ich charakterystyki strukturalne¹. Przedstawione przez nich metody pozwalają m.in. na opisanie szeregu czasowego poprzez następujący zestaw mierzalnych charakterystyk:

$$F_T = \max \left(0, 1 - \frac{\text{Var}(R_t)}{\text{Var}(T_t + R_t)} \right)$$

$$F_S = \max \left(0, 1 - \frac{\text{Var}(R_t)}{\text{Var}(S_t + R_t)} \right)$$

¹Wang, X., Smith, K. A., & Hyndman, R. J. (2006). Characteristic-based clustering for time series data. *Data Mining and Knowledge Discovery*, 13(3), 335–364

gdzie F_T jest miarą siły trendu, natomiast F_S - miarą siły sezonowości. R_t, T_t, S_t reprezentują odpowiednio resztę, trend i sezonowość szeregu.


```
[1] "Siła sezonowości (F_S): 0.0317"
```

```
[1] "Siła trendu (F_T): 0.9459"
```


Analiza składowych szeregu cen srebra wykazała niemal całkowitą dominację trendu nad jego składową sezonową. Amplituda wahań sezonowych (ok. ± 0.5 USD) stanowi zaledwie niecałe 3% całkowitej zmienności szeregu (zakres 5-50 USD), co czyni ją pomijalną z punktu widzenia prognozowania średniokresowego.

Mimo przeprowadzenia pełnej procedury identyfikacji sezonowości, wyniki jednoznacznie wskazują na brak istotnych i stabilnych składowych okresowych. W związku z tym, w dalszej części pracy rezygnujemy z rozbudowy modeli sezonowych.

G..sto.... spektralna reszt (wyg..adzona)



ACF składowej losowej po klasycznej dekompozycji



Na wykresie spektralnej gęstości oś OX reprezentuje liczbę cykli na rok. Na wykresie widzimy dwa główne szczyty, które dominują nad resztą: pierwszy duży pik (ok. $f = 0.6$) to cykl trwający około 20 miesięcy ($1/0.6 \approx 1.67$ roku), natomiast drugi duży pik (ok. $f = 1.25$) to cykl trwający około 10 miesięcy ($1/1.25 \approx 0.8$ roku). Gdyby reszty były “białym szumem”, linia powinna oscylować blisko poziomej przerywanej kreski na całej długości. Tutaj mamy do czynienia z sytuacją, w której pewne częstotliwości mają wielokrotnie większą moc niż inne. Wskazuje to na istnienie cyklu koniunkturalnego lub średniokresowego, którego klasyczny `decompose` nie potrafi odseparować, bo nie powtarza się on idealnie co 12 miesięcy. Ceny srebra często podlegają cyklom inwestycyjnym, które trwają np. ok. 1.5 roku, co możemy zaobserwować analizując wykres gęstości spektralnej. Potwierdzają to również autokorelacje, które widać na wykresie ACF tychże reszt: widoczne wystające słupki poza niebieskie linie przerywane (istotność statystyczna) oznaczają, że w składowej losowej nadal znajdują się informacje, których prosta metoda nie uchwyciła.

Charakter trendu: stochastyczny czy deterministyczny

Augmented Dickey-Fuller Test

```
data: log(silver$price_usd_per_troy_oz)
Dickey-Fuller = -1.8929, Lag order = 6, p-value = 0.6209
alternative hypothesis: stationary
```


Augmented Dickey-Fuller Test

```
data: diff(log(silver$price_usd_per_troy_oz))
Dickey-Fuller = -4.7607, Lag order = 6, p-value = 0.01
alternative hypothesis: stationary
```

W analizie zdecydowano się na przeprowadzenie testów stacjonarności bezpośrednio na logarytmach cen srebra, pomijając testy na danych surowych. Decyzja ta wynika z faktu, że szereg cenowy charakteryzuje się zmiennością proporcjonalną do poziomowi cen (heteroskedastyczność). Transformacja logarymiczna jest niezbędnym krokiem wstępnym, który stabilizuje wariancję szeregu, co jest warunkiem koniecznym dla poprawności wyników testu ADF oraz późniejszego modelowania. Testowanie danych niezlogarytmowanych, w obliczu wyraźnego efektu skali, mogłoby prowadzić do błędnych wniosków statystycznych.

W celu zbadania charakteru trendu przeprowadzono test ADF na zlogarytmowanych danych. Zastosowanie logarytmu naturalnego pozwoliło na stabilizację wariancji szeregu oraz umożliwiło interpretację wyników w kategoriach stóp zwrotu. Wyniki testu ADF dla logarytmów poziomów nie dają podstaw do odrzucenia hipotezy zerowej o braku stacjonarności ($p = 0.62$). Dopiero pierwsze różnicowanie logarytmów pozwoliło na odrzucenie hipotezy zerowej ($p < 0.01$). Oznacza to, że proces jest zintegrowany rzędu pierwszego, $I(1)$, a występujący w nim trend ma charakter stochastyczny. Taka struktura szeregu wyklucza stosowanie prostych modeli trendu deterministycznego na rzecz modeli różnicowych typu ARIMA.

Analiza zmian strukturalnych



Wykryto istotne zmiany strukturalne w latach: 2010.7, 2013.8, 2019.8, 2022.9

Ceny surowców często podlegają nagłym zmianom reżimu związanym z kryzysami finansowymi, interwencjami banków centralnych lub szokami popytowymi. W celu weryfikacji stabilności strukturalnej szeregu zastosowano procedurę identyfikacji punktów załamania (breakpoints), która pozwala wykryć momenty istotnych zmian poziomu średniego. Zidentyfikowane punkty zmian strukturalnych odpowiadają znanym epizodom niestabilności rynku srebra, w szczególności okresowi globalnego kryzysu finansowego (2008–2009) oraz aprecjacji spekulacyjnej z 2011 roku. Obecność wielu reżimów potwierdza, że proces cenowy nie jest jednorodny w czasie. Po ograniczeniu analizy do względnie stabilnego podokresu (2014–2018) gęstość spektralna ulega dalszemu spłaszczeniu, co jest typowe dla procesu zbliżonego do białego szumu. Oznacza to, że obserwowane wcześniej piki mają charakter przejściowy i są konsekwencją zmian strukturalnych, a nie istnienia trwałej cykliczności.

Model stochastyczny ARIMA

Series: y
ARIMA(0,0,1) with non-zero mean

Coefficients:

ma1	mean
0.2870	0.0095
s.e.	0.0616 0.0056

sigma² = 0.004816: log likelihood = 314.45
AIC=-622.9 AICc=-622.81 BIC=-612.33

Ze względu na stwierdzony trend stochastyczny typu $I(1)$ modelowanie przeprowadzono na pierwszych różnicach logarytmów cen srebra, co pozwala interpretować zmienność w kategoriach względnych zmian cen. Automatyczna procedura identyfikacji wskazała model ARIMA(0,0,1) z niezerową średnią jako najlepszy kompromis pomiędzy dopasowaniem a parsymonią. Istotny parametr MA(1) świadczy o krótkookresowej zależności losowej, natomiast brak składników autoregresyjnych potwierdza brak długiej pamięci procesu. Wynik ten jest spójny z charakterystyką rynków surowcowych, gdzie zmiany cen są w dużej mierze napędzane nową informacją.

```
[1] "Test serii (Stevensa) na losowość:"
```

```
Runs Test
```


```
data:  as.factor(eps_bin)
Standard Normal = -0.69547, p-value = 0.4868
alternative hypothesis: two.sided
```

```
[1] "Test Kołmogorowa-Smirnowa:"
```


```
Asymptotic one-sample Kolmogorov-Smirnov test
```

```
data:  eps_std
D = 0.037789, p-value = 0.866
alternative hypothesis: two-sided
```

ACF dla reszt



ACF dla kwadratów reszt (AR



Test Stevensa nie wykazał istotnych odstępstw od losowości ($p\text{-value} = 0.80$), co oznacza, że reszty modelu ARIMA(0,0,1) są losowe. Test Kołmogorowa-Smirnowa z kolei potwierdził zgodność standaryzowanych reszt z rozkładem normalnym ($p\text{-value} = 0.91$). Brak istotnych autokorelacji zarówno w resztach, jak i w ich kwadratach wskazuje, że model ARIMA skutecznie wyeliminował zależności liniowe oraz większość potencjalnych efektów heteroskedastyczności. Sugeruje to, że wystrzały ceny to jednorazowe impulsy, a nie wejście rynku w fazę długiej destabilizacji.

Mimo wstępnych przesłanek (pojedyncze lągi w ACF kwadratów reszt), zdecydowano o pominięciu modelu GARCH w ostatecznej specyfikacji. Diagnostyka modelu sGARCH(1,1) wykazała brak istotności parametrów strukturalnych oraz brak poprawy kryterium AIC względem modelu ARIMA. Zgodnie z procedurą selekcji modeli (funkcja `autogarch` z

G..sto.... spektralna reszt (wyg..adzona)



Ostateczna weryfikacja modelu ARIMA poprzez analizę spektralną reszt (wykres gęstości spektralnej reszt) potwierdza wysoką jakość dopasowania. W przeciwieństwie do reszt z dekompozycji klasycznej, gęstość widmowa reszt modelu ARIMA nie wykazuje żadnych dominujących pików dla częstotliwości cyklicznych, ponieważ maksymalne wartości gęstości spadły z poziomu 0.17 do ok. 0.01, a ich rozkład ma charakter chaotyczny, typowy dla białego szumu. Oznacza to, że model skutecznie wyeliminował z szeregu wszystkie zależności autokorelacyjne i cykle średniookresowe.


laboratoriów), przy braku trwałej heteroskedastyczności warunkowej, model ARIMA(0,1,1), zbudowany na szeregu zlogarytmowanym, stanowi optymalne narzędzie prognostyczne, ponieważ najlepiej opisuje dynamikę logarytmicznych stóp zwrotu cen srebra, minimalizując kryterium AIC.

Proгноza

Proгноza cen srebra: ARIMA vs ETS

Dane historyczne + prognoza na 2 lata

 ARIMA  ETS



[1] "Dokładność ARIMA:"

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	0.01756463	1.512284	1.068975	0.02871236	5.264644	0.2392093
Test set	9.03176820	13.157373	9.032087	18.79173109	18.792781	2.0211506
ACF1	Theil's U					
Training set	-0.04951604	NA				
Test set	0.56099380	2.646442				

[1] "Dokładność ETS:"

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	0.09896534	1.55025	1.091939	0.3863025	5.400731	0.2443481

Test set	9.21934267	13.37643	9.225608	19.2130986	19.233708	2.0644555
	ACF1 Theil's U					
Training set	0.1987949	NA				
Test set	0.5642650	2.694255				

Porównanie modeli ARIMA i ETS na zbiorze testowym wykazało zbliżoną jakość prognoz, przy nieznacznej przewadze modelu ARIMA. W obu przypadkach błędy prognoz rosną wraz z horyzontem, co jest typowe dla rynków o wysokiej niepewności i ograniczonej przewidywalności. Mimo że diagnostyka reszt potwierdza wysoką wiarygodność statystyczną modelu ARIMA(0,0,1), prognoza punktowa znajduje się poniżej ostatnich wartości rynkowych. Wynika to z charakterystyki modeli klasy ARIMA, które w horyzoncie długookresowym wykazują tendencję do powrotu do historycznej średniej stopy wzrostu. Obecne poziomy cen srebra są interpretowane przez model jako silne odchylenie od trendu stochastycznego, co skutkuje konserwatywną predykcją. Wskazuje to na konieczność uwzględnienia wysokiej niepewności rynkowej, co potwierdzają szerokie przedziały ufności prognozy.

Wnioski

Analiza wykazała, że dynamika cen srebra jest zdominowana przez trend stochastyczny oraz losowe fluktuacje krótkookresowe, przy braku istotnej sezonowości i stabilnej cykliczności. Po transformacji logarytmicznej i różnicowaniu uzyskano proces stacjonarny, którego struktura została poprawnie opisana modelem ARIMA(0,0,1). Dodatkowa analiza spektralna i testy stabilności potwierdziły, że zaobserwowane oscylacje mają charakter przejściowy i wynikają głównie ze zmian strukturalnych rynku.

Analiza szeregu czasowego dla miesięcznej ceny uncji miedzi

Pytania badawcze

1. Czy szereg wykazuje trend lub sezonowość?
2. Czy po transformacji (log, różnice) szereg jest stacjonarny?
3. Który model (ETS/ARIMA/baseline) daje najlepszą prognozę na 12–24 miesiące?
4. Czy w danych występują zmiany strukturalne?

EDA: wykres, rozkład, outliery

Szereg cen miedzi wykazuje inną charakterystykę niż złoto. Miedź jest metalem ściśle przemysłowym, dlatego jej cena silnie reaguje na cykle koniunkturalne, pełniąc rolę barometru globalnej gospodarki.



W przeciwieństwie do złota, które często rośnie w czasie niepokoїв jako “bezpieczna przystań”, miedź wykazuje większą zmienność cykliczną, podążając za tempem globalnego wzrostu PKB.


Gwałtowny spadek (2008/2009): Reakcja na Globalny Kryzys Finansowy i załamanie popytu inwestycyjnego.

Trend spadkowy (2011–2016): Wynikał ze spowolnienia gospodarczego w Chinach (największego konsumenta miedzi) oraz nadpodaży surowca po okresie inwestycyjnym (“koniec supercyklu surowcowego”).

Szok COVID-19 (2020): Krótkotrwale załamanie, po którym nastąpiło dynamiczne odbicie wywołane stymulacją fiskalną i zaburzeniami łańcuchów dostaw.

Okres niepewności (2022–obecnie): Wybuch wojny w Ukrainie początkowo wywindował ceny (obawy o podaż), jednak w drugiej połowie 2022 roku nastąpiła korekta spowodowana podwyżkami stóp procentowych (walka z inflacją) oraz polityką “Zero-COVID” w Chinach. Obecnie obserwujemy *trend boczny* - rynek balansuje między obawami o recesję a rosnącym popytem ze strony sektora transformacji energetycznej (OZE, samochody elektryczne).


Rozkład cen miedzi (miesi.cznie)



Rozkład cen miedzi w badanym okresie jest jednomodalny (posiada jedno główne maksimum), z najsilniejszą koncentracją obserwacji w przedziale 0.20–0.25 USD/oz. Wskazuje to, że mimo licznych wahań koniunkturalnych, rynek miedzi najczęściej dążył do równowagi w tym właśnie zakresie cenowym.

W przeciwieństwie do złota, którego rozkład charakteryzował się silną asymetrią prawostronną (długi ogon oznaczający ucieczkę cen w górę), rozkład miedzi jest bardziej symetryczny, lecz szeroki (duża dyspersja). Oznacza to, że miedź jest aktywem o wysokiej zmienności w obie strony – ceny potrafią dynamicznie rosnąć w czasie boomu, ale też głęboko spadać w czasie recesji, rzadko jednak wybijając się trwale na ekstremalnie wysokie poziomy bez późniejszej korekty.

Heatmapa cen miedzi: miesi.c vs rok




Podobnie jak w przypadku złota, mapa ciepła dla miedzi wskazuje na dominację zmian między latami (poziome pasy) nad zmianami wewnątrz roku (sezonowość miesięczna). Wyraźnie widać „ciemne pasy” w latach boomu surowcowego (ok. 2011 oraz po 2020 r.) oraz „jasne obszary” odpowiadające niższym poziomom cenowym: na początku badanego okresu (2005) oraz w latach spowolnienia gospodarczego (koniec 2008/2009, 2015/2016). Brak wyraźnych pionowych pasów sugeruje, że sezonowość kalendarzowa (np. wzrosty zawsze w marcu) jest słabsza niż wpływ globalnych trendów makroekonomicznych.

Dekompozycja szeregu

Przeprowadzono dekompozycję szeregu czasowego metodą STL, wyodrębniając składową trendu, sezonowości oraz reszt.

Dekompozycja cen miedzi (STL)




Dominacja Trendu i Cyklu: Głównym czynnikiem kształtującym cenę miedzi jest składowa trendu (panel trend). Nie jest ona liniowa, lecz wykazuje silną cykliczność, z wyraźnymi załamaniami w okresach recesji (2008, 2020). Potwierdza to, że miedź jest surowcem wrażliwym na koniunkturę gospodarczą.

Marginalna Sezonowość: Panel seasonal wskazuje na istnienie powtarzalnego wzorca rocznego, jednak jego siła jest znikoma. Analizując szare paski skali, widzimy, że wahania sezonowe mają amplitudę rzędu ~ 0.008 USD/oz, co stanowi ułamek wartości surowca (ok. 2-3% ceny). Oznacza to, że choć matematycznie można wyodrębnić pewną sezonowość, to ekonomicznie jest ona zagłuszana przez silne zmiany trendu i szoki rynkowe.


Trend: aproksymacja wielomianowa

Przyjęto maksymalny stopień wielomianu równy 12, analogicznie do analizy złota. Choć kryterium AIC sugeruje dalszy spadek wartości dla wyższych stopni, ograniczenie to wynika z chęci uniknięcia nadmiernego dopasowania oraz braku ekonomicznego uzasadnienia dla stosowania wielomianów tak wysokiego rzędu do opisu cykli surowcowych.

Dobór stopnia wielomianu trendu (AIC)




Trend wielomianowy miedzi (stopień 12)



Mimo zastosowania wielomianu wysokiego stopnia (12), dopasowana krzywa nie oddaje precyzyjnie dynamiki cen miedzi. Przebieg trendu wielomianowego jest z natury zbyt "gładki" i łagodny, przez co model "ścina" ostre punkty zwrotne (głębokie dolki kryzysowe w 2008 i 2020 roku oraz gwałtowne szczyty). Wskazuje to, że sztywna funkcja matematyczna nie jest w stanie w pełni odwzorować złożonej, ostrej cykliczności surowca, co uzasadnia przejście do bardziej elastycznych metod wygładzania (MA, EWMA).

Wyglądanie: MA i EWMA

Zastosowano dwie metody wygładzania szeregu: prostą średnią ruchomą MA(12) oraz średnią wykładniczą EWMA.



Analiza wykresu pokazuje, że obie metody radzą sobie z opisem trendu znacznie lepiej niż sztywny model wielomianowy, poprawnie podążając za cyklicznymi zwrotami cen. Warto jednak zauważyć przewagę metody EWMA (linia brązowa), która dzięki mechanizmowi wykładniczych wag szybciej reaguje na gwałtowne zmiany rynkowe (np. odbicie po COVID-19 w 2020 r.) i ściślej przylega do rzeczywistego przebiegu cen. Metoda MA(12) (linia czarna), choć skutecznie eliminuje szum, wykazuje zauważalne opóźnienie (efekt inercji) w punktach zwrotnych, co jest naturalną cechą średnich arytmetycznych o stałych wagach.

Stacjonarność i transformacje

```
[1] "ADF dla log(ceny):"
```

Augmented Dickey-Fuller Test

```
data: na.omit(copper$log_price)
Dickey-Fuller = -3.4627, Lag order = 6, p-value = 0.04701
alternative hypothesis: stationary
```

```
[1] "ADF dla zwrotów (diff log):"
```

Augmented Dickey-Fuller Test

```
data: na.omit(copper$dlog_price)
Dickey-Fuller = -6.0748, Lag order = 6, p-value = 0.01
alternative hypothesis: stationary
```

Wynik testu dla **logarytmu cen** jest niejednoznaczny. P-value wynosi 0.047, co jest wartością graniczną (tuż poniżej progu 0.05). Formalnie sugerowałoby to stacjonarność wokół trendu (trend deterministyczny), jednak wizualna ocena wykresu i charakter danych giełdowych wskazują na niestacjonarność.

Natomiast dla **pierwszych różnic (log-zwrotów)** test daje bardzo silny wynik ($p < 0.01$), co jednoznacznie potwierdza stacjonarność. Dlatego, mimo granicznego wyniku dla poziomów, w dalszym modelowaniu (ARIMA) traktujemy proces jako niestacjonarny (z trendem stochastycznym) i wymagający różnicowania. Oznacza to, że przyszła cena zależy od skumulowanych, losowych szoków rynkowych, a nie tylko od upływu czasu.

Modelowanie i prognoza (Train 2005-2023 / Test 2024)


Porównanie metryczne

```
# A tibble: 6 x 3
  model      RMSE  MAPE
  <chr>    <dbl> <dbl>
1 ARIMA (BoxCox) 0.0216  5.74
2 ARIMA         0.0224  6.43
```

3 DRIFT	0.0237	6.57
4 ETS	0.0255	7.31
5 ETS (BoxCox)	0.0274	7.89
6 NAIVE	0.0278	8.06

Najlepsze wyniki prognostyczne na zbiorze testowym osiągnął model **ARIMA z transformacją Boxa-Coxa**, uzyskując najniższy błąd RMSE (0.0216) oraz MAPE (5.74%). Wynik ten potwierdza wcześniejsze wnioski z analizy EDA – miedź charakteryzuje się zmienną wariancją (amplituda wahań zależy od poziomu cen), dlatego zastosowanie transformacji stabilizującej (Box-Cox) pozwoliło na lepsze dopasowanie modelu niż w przypadku klasycznej ARIMY czy modeli wykładniczych (ETS). Słabszy wynik modelu NAIVE (ostatnie miejsce) świadczy o tym, że w danych występuje struktura (autokorelacja/trend), którą modele zaawansowane potrafiły wykorzystać.


Porównanie wizualne



Rzeczywisty kurs miedzi w 2024 roku (ciągła linia) wykazał silną zmienność (gwałtowny skok w pierwszej połowie roku i późniejszą korektę), której modele statystyczne oparte na historii nie były w stanie precyzyjnie odwzorować co do kształtu. Jest to zjawisko typowe dla szeregów surowcowych, gdzie lokalne szoki (popytowe/podażowe) odchylają cenę od trendu długoterminowego. Mimo to, niski błąd MAPE (~5.7%) wskazuje, że model poprawnie określił przeciętny poziom cen w badanym okresie.


Finalna prognoza 24 miesiące do przodu

Prognozę na kolejne 24 miesiące wygenerowano przy użyciu najlepszego modelu: ARIMA z transformacją Boxa-Coxa.



Model sugeruje, że choć najbardziej prawdopodobnym scenariuszem jest utrzymanie obecnych poziomów cenowych, rynek miedzi pozostaje obciążony gigantycznym ryzykiem. W perspektywie 2 lat cena z 95-procentowym prawdopodobieństwem może znaleźć się w przedziale od kryzysowych 0.15 USD do rekordowych 0.40 USD. Oznacza to, że przyszłość rynku zależy nie od trendu technicznego, lecz od nadchodzących impulsów fundamentalnych (np. tempo transformacji energetycznej vs. globalna recesja).

Zmiany strukturalne (PELT)



Kluczowe punkty zwrotne wykryte przez algorytm pokrywają się z najważniejszymi wydarzeniami makroekonomicznymi:

- Gwałtowny spadek: Odpowiada załamaniu podczas Globalnego Kryzysu Finansowego (2008/2009).
- Wzrost poziomu: To okres boomu surowcowego i odbicia w Chinach (2011).
- Skokowa zmiana w górę: Reakcja rynków na post-pandemiczną stymulację i inflację po roku 2020.

Wynik ten stanowi ostateczne potwierdzenie, że parametry generujące proces cenowy nie są stałe w czasie. Występowanie tak silnych zmian strukturalnych jest koronnym argumentem przeciwko stosowaniu prostych modeli liniowych na całej 20-letniej próbie i w pełni uzasadnia konieczność stosowania modeli adaptacyjnych (takich jak użyta wcześniej ARIMA z transformacją Boxa-Coxa), które potrafią dostosować się do zmieniającej się zmienności rynku.

Podsumowanie analizy miedzi

Analiza miesięcznych cen miedzi wskazuje na silną naturę cykliczną surowca (naprzemienne okresy boomu i recesji skorelowane z koniunkturą gospodarczą), przy czym sezonowość miesięczna jest marginalna i ekonomicznie pomijalna w porównaniu do składowej trendu. Testy stacjonarności dały wynik graniczny dla $\log(\text{cena})$ ($p\text{-value} \approx 0.047$), jednak ze względu na charakter danych giełdowych oraz jednoznaczny wynik dla $\text{diff}(\log(\text{cena}))$ (silne odrzucenie hipotezy o niestacjonarności), szereg modelowano jako proces zintegrowany $I(1)$. W porównaniu modeli prognostycznych na zbiorze testowym ($h = 12$, rok 2024) najlepsze wyniki uzyskał model ARIMA z transformacją Box–Cox (najniższe RMSE i MAPE). Zastosowanie tej transformacji było kluczowe ze względu na zmienną wariancję (amplituda wahań rośnie wraz z poziomem cen). Model ten pokonał proste benchmarki (NAIVE, DRIFT), co potwierdza istnienie struktury zależności możliwej do prognozowania, mimo trudnego rynku w 2024 roku. Finalna prognoza 24-miesięczna wskazuje na stabilizację poziomu cen (zachowawczy charakter modelu), ale obciążona jest **ogromną niepewnością** (bardzo szerokie przedziały ufności). Analiza zmian strukturalnych (PELT) potwierdziła występowanie **odrębnych reżimów zmienności**, pokrywających się z kluczowymi szokami makroekonomicznymi (2008, 2011, 2020), co tłumaczy wyższość metod adaptacyjnych (EWMA, ARIMA) nad sztywnymi trendami deterministycznymi.

Podsumowanie

Projekt obejmuje analizę dynamiki cen srebra, miedzi i złota w latach 2005–2025, ze szczególnym naciskiem na identyfikację komponentów losowych, zmienności oraz reakcji rynku na globalne szoki gospodarcze. Ze względu na niestacjonarność szeregów poziomów, analiza została przeprowadzona na logarytmach i pierwszych różnicach ($I(1)$), co pozwoliło uzyskać procesy stacjonarne i poprawnie zastosować modele prognostyczne.

W ramach modelowania porównano podejścia ARIMA i ETS, a ich jakość oceniono na podstawie diagnostyki reszt (ACF, testy heteroskedastyczności Gldfelda-Quandta i Breuscha-Pagana) oraz miar błędu prognoz (MAPE, RMSE). Analiza zmian strukturalnych (test PELT) potwierdziła występowanie okresowych załamień cenowych, jednak mimo tych zaburzeń model ARIMA(0,1,1) z transformacją Boxa–Coxa okazał się najbardziej oszczędny i stabilny. Uzyskane wyniki wskazują na stopniową stabilizację ryzyka rynkowego w prognozowanym horyzoncie do 2026 roku.

Źródła

- Wang, X., Smith, K. A., & Hyndman, R. J. (2006). Characteristic-based clustering for time series data. *Data Mining and Knowledge Discovery*, 13(3), 335–364
- Forecasting: Principles and Practice (2nd edition), Rob J Hyndman and George Athanasopoulos, Monash University, Australia